

# Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

<sup>1</sup> Lucas Kerr do Amaral, <sup>2</sup> Marcela Nalesso

<sup>1</sup> Ciência da Computação – FEI <sup>2</sup> Ciência da Computação – FEI

<sup>1</sup> lamaral2002@gmail.com, <sup>2</sup> marcelanalesso@gmail.com

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira laferreira@fei.edu.br

**Resumo:** Diante da insuficiência performática em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via *Principal Component Analysis* (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

**Palavras-chaves:** Sistemas de Detecção de Intrusões, Machine Learning, Seguranças da sInformação, Análise de Dados, Redução de Dimensionalidade e Cybersegurança.

## 1. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Com o aumento do volume de dados trafegados e da complexidade das infraestruturas, observa-se também um crescimento expressivo na quantidade e sofisticação dos ataques, como negações de serviço, varreduras de rede e acessos não autorizados. Esse cenário evidencia a necessidade de mecanismos eficazes de monitoramento e proteção, capazes de identificar comportamentos maliciosos em tempo hábil. Nesse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de *Machine Learning* tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender

exclusivamente de regras pré-definidas. No entanto, a eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD e UNSW-NB15 têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a *Principal Component Analysis* (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de *Machine Learning* aplicadas à detecção de intrusões, identificando

atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de *Principal Component Analysis* (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em *Machine Learning*, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

## II. Fundamentação Teórica

### A. Segurança da Informação e Ameaças em Redes

A segurança da informação tornou-se um elemento central na sociedade contemporânea devido à crescente dependência de sistemas digitais. Com a consolidação da chamada “civilização cibernética”, iniciada a partir da revolução digital no final do século XX, houve um aumento significativo na produção e circulação de dados, ampliando a superfície de ataque para agentes maliciosos [14]. Dados recentes indicam que o tráfego global per capita evoluiu de 16 GB mensais em 2017 para projeções superiores a 50 GB em

2022, enquanto mais de 14 bilhões de registros foram comprometidos desde 2013, evidenciando a magnitude das ameaças digitais [4] [15]. Nesse contexto, a Segurança da Informação fundamenta-se na preservação da tríade confidencialidade, integridade e disponibilidade, tornando-se essencial para a proteção de ativos digitais em ambientes cada vez mais interconectados [3] [4] [9].

A evolução das ameaças cibernéticas acompanha diretamente o avanço tecnológico, tornando os ataques mais sofisticados e diversificados. Entre os principais tipos de ataques identificados na literatura estão os ataques de negação de serviço (DoS), varreduras de rede (Probe), acessos remotos não autorizados (R2L) e escalonamento de privilégios (U2R), cada um explorando vulnerabilidades específicas dos sistemas [3]. Além disso, observa-se o crescimento expressivo dos ataques de dia zero, que exploram falhas ainda desconhecidas, dificultando a detecção por mecanismos tradicionais. Dessa forma, a complexidade e o volume das ameaças exigem soluções capazes de operar em ambientes de grande escala e alta velocidade.

No presente, mais de 61% das interações industriais e sociais ocorrem em ambiente online, o que torna a rede um alvo estratégico para cibercrimes que agora visam não apenas usuários finais, mas diretamente infraestruturas críticas e instituições bancárias. Essa dependência tecnológica exige que os Sistemas de Detecção de Intrusão (IDS) evoluam proporcionalmente à sofisticação das ameaças [3].

### B. Sistemas de Detecção de Intrusão

Os Intrusion Detection System constituem uma das principais ferramentas para monitoramento e identificação de atividades maliciosas em redes. Desde o primeiro modelo formal proposto em 1987, os IDS evoluíram de abordagens estatísticas simples para sistemas inteligentes capazes de analisar grandes volumes de dados em tempo real [14]. Esses sistemas atuam como uma camada adicional de segurança, monitorando eventos e gerando alertas quando comportamentos suspeitos são identificados. Assim, os IDS desempenham papel fundamental na mitigação de ataques e na proteção de infraestruturas críticas.

Os IDS podem ser classificados tanto pela fonte de dados quanto pela abordagem de detecção. Em relação à origem das informações, destacam-se os sistemas baseados em rede (NIDS) e os baseados em host (HIDS) [3] [12], enquanto, quanto à técnica utilizada, dividem-se em sistemas baseados em assinatura (SIDS) e baseados em anomalia (AIDS) [8] [15] [1]. Os sistemas baseados em assinatura são eficazes na identificação de ataques conhecidos, porém incapazes de detectar ameaças inéditas, como ataques de dia zero [4] [14]. Por outro lado, os sistemas baseados em anomalia apresentam maior flexibilidade, mas

sofrem com altas taxas de falsos positivos, o que impacta diretamente sua aplicabilidade prática [15] [13].

A literatura destaca que os IDS enfrentam desafios significativos relacionados ao volume e à complexidade dos dados de rede. Com o crescimento exponencial do tráfego e a geração massiva de dados, os sistemas tradicionais tornam-se incapazes de processar informações em tempo real sem perda de desempenho. Além disso, a presença de atributos redundantes e irrelevantes nos datasets compromete a eficiência dos modelos de detecção. Esse cenário evidencia a necessidade de soluções mais inteligentes e adaptativas, capazes de lidar com ambientes de Big Data.

### C. Machine Learning aplicado à detecção de intrusão

O Machine Learning surge como uma abordagem promissora para superar as limitações dos IDS tradicionais. Ao permitir que sistemas aprendam padrões diretamente dos dados, o aprendizado de máquina possibilita a identificação de comportamentos anômalos e a adaptação a novos tipos de ataques [7] [12] [8]. Estudos recentes apontam um crescimento significativo no uso de técnicas de ML e Deep Learning na detecção de intrusões, especialmente a partir de 2018. Dessa forma, o ML se consolida como um componente essencial para o desenvolvimento de IDS mais eficientes.

Entre os paradigmas de aprendizado, o modelo supervisionado destaca-se como o mais utilizado na literatura [14] [8]. Essa abordagem utiliza dados previamente rotulados para treinar modelos capazes de classificar o tráfego de rede como normal ou malicioso. A disponibilidade de bases de dados como NSL-KDD e CICIDS-2017 favorece a aplicação desse tipo de técnica, permitindo comparações padronizadas entre diferentes modelos. Assim, o aprendizado supervisionado torna-se a base para a construção de sistemas de detecção mais precisos.

Entretanto, a aplicação de ML em IDS enfrenta desafios relacionados à alta dimensionalidade dos dados. A presença de atributos redundantes aumenta o custo computacional e pode reduzir a acurácia dos modelos. Nesse contexto, técnicas de seleção de atributos tornam-se essenciais para identificar características relevantes e reduzir a complexidade do sistema. A literatura demonstra que é possível reduzir significativamente o número de atributos sem perda de desempenho, melhorando a eficiência dos modelos [6].

### D. Algoritmos de classificação

Diversos algoritmos de classificação têm sido aplicados na detecção de intrusões, cada um apresentando vantagens e limitações específicas. Entre os mais utilizados destacam-se o Random Forest, o Support Vector Machine, o K-Nearest Neighbors, as árvores de

decisão e o Naive Bayes. Esses algoritmos diferem em termos de desempenho, complexidade computacional e capacidade de generalização. Dessa forma, a escolha do modelo adequado depende diretamente das características do conjunto de dados e do problema abordado.

O Random Forest destaca-se pela alta acurácia e robustez, alcançando taxas superiores a 99% em bases como KDD Cup 99 e NSL-KDD [2] [5]. Esse algoritmo utiliza múltiplas árvores de decisão para reduzir o risco de sobreajuste. Por outro lado, o SVM apresenta bom desempenho em espaços de alta dimensionalidade, embora sua eficiência dependa fortemente da escolha dos parâmetros [2] [4] [13]. Assim, ambos os algoritmos são amplamente utilizados em cenários de detecção de intrusão.

Outros algoritmos também desempenham papel relevante na literatura. O KNN destaca-se pela simplicidade, mas possui alto custo computacional na fase de classificação, enquanto as árvores de decisão oferecem interpretabilidade, sendo úteis para análise de regras [2] [8] [4]. Já o Naive Bayes apresenta boa eficiência computacional, embora sua suposição de independência entre atributos possa limitar seu desempenho [2] [8] [11]. Dessa forma, a combinação de diferentes algoritmos, por meio de técnicas ensemble, tem sido explorada para melhorar os resultados.

Estudos indicam que a integração entre algoritmos de classificação e técnicas de seleção de atributos é fundamental para alcançar alto desempenho em IDS [2] [10]. A redução de dimensionalidade permite diminuir o custo computacional e aumentar a velocidade de processamento, especialmente em redes de alta velocidade. Além disso, a escolha adequada de atributos contribui diretamente para a melhoria da acurácia e redução de falsos positivos [6]. Assim, a combinação dessas técnicas representa uma abordagem eficaz para a construção de sistemas de detecção mais robustos.

### E. Métricas de Avaliação

## III. Cronograma

| Etapas                                     | 2026 |     |     |     |     |
|--------------------------------------------|------|-----|-----|-----|-----|
|                                            | Fev  | Mar | Abr | Mai | Jun |
| Pesquisa para conhecimento do público-alvo | X    | X   |     |     |     |
| Pesquisa de opinião sobre o público-alvo   |      | X   | X   |     |     |
| Desenvolvimento do projeto                 |      |     | X   | X   |     |
| Testes e validação                         |      |     |     | X   | X   |
| Finalização do TCC                         |      |     |     |     | X   |

## IV. Resultados Preliminares

### A. Análise de Dados e Pré-processamento

Para a análise de dados foi considerado a base de dados NSL-KDD com os seguintes

ataques: *neptune*, *satan*, *ipsweep*, *poetsweep*, *smurf*, *nmap*, *back*, *teardrop*, *warezclient*, *pod*, *guess\_passwd*, *buffer\_overflow*, *warezmaster*, *land*, *imap*, *rootkit*, *loadmodule*, *ftp\_write*, *multihop*, *phf*, *perl*, *spy*. alguns dos valores citados não são ataques reais, porém no contexto desta análise componentes como: *loadmodule*, *perl* e *nmap* foram categorizados como ataques.

|                 |       |
|-----------------|-------|
| normal          | 67343 |
| neptune         | 41214 |
| satan           | 3633  |
| ipsweep         | 3599  |
| portsweep       | 2931  |
| smurf           | 2646  |
| nmap            | 1493  |
| back            | 956   |
| teardrop        | 892   |
| warezclient     | 890   |
| pod             | 201   |
| guess_passwd    | 53    |
| buffer_overflow | 30    |
| warezmaster     | 20    |
| land            | 18    |
| imap            | 11    |
| rootkit         | 10    |
| loadmodule      | 9     |
| ftp_write       | 8     |
| multihop        | 7     |
| phf             | 4     |
| perl            | 3     |
| spy             | 2     |

Tabela I. Dados presentes na base NSL-KDD

Para melhor visualização dos dados os ataques foram separados nas seguintes categorias: *normal*, *dos*, *probe*, *r2l*, *u2r*.

| Categoria | Tipos de Ataque                                                                           |
|-----------|-------------------------------------------------------------------------------------------|
| normal    | Normal                                                                                    |
| dos       | Neptune<br>smurf<br>teardrop<br>pod<br>land                                               |
| probe     | nmap<br>ipsweep<br>satan                                                                  |
| r2l       | warezclient<br>warezmaster<br>guess_passwd<br>imap<br>ftp_write<br>multihop<br>phf<br>spy |
| u2r       | buffer_overflow<br>rootkit<br>loadmodule<br>perl                                          |

Tabela II. Definição de tipos de ataque por grupos

A matriz de correlação mostra que, a contagem de pacotes e ocorrência de erros são os componentes com maior correlação.





Figura 1. Matriz de correlação da base NSL\_KDD


Para validar as informações da matriz de correlação foi feita uma análise baseada em *PCA*, plotando um gráfico com os dois primeiros componentes e separando os valores pelos grupos anteriormente mencionados na tabela ??.



**Figura 2.** visualização de dois componentes do PCA separado por classes

### B. Redução de Dimensionalidade e Seleção de Atributos

Buscando uma margem de variância a cima de 95% foi calculado o *PCA* para variados números de componentes, para descobrir a melhor variância, com o menor número de componentes. Definido 23 componentes como a melhor média amostral



**Figura 3.** Variância explicada para PCA

## V. Metodologia

O algoritmo utilizado para as análises foi o *DecisionTree*, este conta com o menor tempo de teste e melhor acurácia, estes valores são a maior métrica utilizada pois o objetivo do sistema é ser executado em tempo real para garantir uma resposta rápida a incidentes.

Utilizando os testes do capítulo anterior, foi desenvolvida uma análise com os variados algoritmos mais utilizados (*RandomForest*, *DecisionTree*, *KNN*,


*SVM*, *LogisticRegression*). Utilizando um random state de 42 para os algoritmos citados, obtiveram-se os seguintes valores:

| Modelo              | Acurácia | Precisão | Recall | F1-Score |
|---------------------|----------|----------|--------|----------|
| Random Forest       | 0.9987   | 0.9992   | 0.9979 | 0.9985   |
| Decision Tree       | 0.9977   | 0.9975   | 0.9975 | 0.9975   |
| KNN                 | 0.9935   | 0.9921   | 0.9940 | 0.9931   |
| Logistic Regression | 0.9454   | 0.9504   | 0.9313 | 0.9408   |
| SVM (linear)        | 0.9544   | 0.9594   | 0.9418 | 0.9506   |

**Tabela III.** Estatísticas de treino dos modelos

Dados os valores da tabela ?? o algoritmo selecionado foi o *Decision Tree*, dado seu baixo tempo de teste e alta acurácia.

Utilizando os valores anteriormente definidos na figura ?? para uma melhor visualização dos dados que realmente importam, o gráfico foi dividido entre ataques e tráfego normal:



**Figura 4.** PCA classificando tráfego como ataque e normal

## VI. Considerações Finais e Perspectivas Futuras

Nesta primeira etapa foi definido o algoritmo de machine learning utilizado e feitas as análises dos componentes para definição dos componentes mais importantes

## VII. Referências

- [1] E. E. Abdallah, W. Eleisah e A. F. Otoom, "Intrusion Detection Systems using Supervised Machine Learning Techniques: A survey," 2022. DOI: 10.1016/2022.03.029
- [2] O. H. Abdulganiyu, T. A. Tchakoucht e Y. K. Saheed, "A systematic literature review for network intrusion detection system (IDS)," *International Journal of Information Security*,



- vol. 22, pp. 1233–1262, 2023. DOI: 10.1007/s10207-023-00682-2
- [3] W. S. Admass, Y. Y. Munaye e A. A. Diro, “Cyber security: State of the art, challenges and future directions,” 2023. DOI: 10.1016/2023.10031
- [4] Z. Azam, M. M. Islam e M. N. Huda, “Comparative Analysis of Intrusion Detection Systems and Machine Learning-Based Model Analysis Through Decision Tree,” 2023. DOI: 10.1109/2023.3296444
- [5] M. C. Belavagi e B. Muniyal, “Performance Evaluation of Supervised Machine Learning Algorithms for Intrusion Detection,” *Procedia Computer Science*, vol. 89, pp. 117–123, 2016. DOI: 10.1016/j.procs.2016.06.016
- [6] F. Iglesias e T. Zseby, “Analysis of network traffic features for anomaly detection,” 2014. DOI: 10.1007/10994-014-5473-9
- [7] J. Jabez e B. Muthukumar, “Intrusion Detection System (IDS): Anomaly Detection Using Outlier Detection Approach,” *Procedia Computer Science*, vol. 48, pp. 338–343, 2015. DOI: 10.1016/j.procs.2015.04.191
- [8] A. Khraisat, I. Gondal, P. Vamplew e J. Kamruzzaman, “Survey of intrusion detection systems: techniques, datasets and challenges,” *Cybersecurity*, vol. 2, n.º 1, pp. 1–22, 2019. DOI: 10.1186/s42400-019-0038-7
- [9] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin e K.-Y. Tung, “Intrusion detection system: A comprehensive review,” *Journal of Network and Computer Applications*, vol. 36, n.º 1, pp. 16–24, 2013. DOI: 10.1016/j.jnca.2012.09.004
- [10] S. M. Othman, F. M. Ba-Alwi, T. Nabeel e A. Y. Al-Hashida, “Intrusion detection model using machine learning algorithm on Big Data environment,” *Journal of Big Data*, vol. 5, n.º 1, p. 34, 2018. DOI: 10.1186/s40537-018-0145-4
- [11] M. M. Rathore, A. Ahmad e A. Paul, “Real time intrusion detection system for ultra-high-speed big data environments,” *The Journal of Supercomputing*, vol. 72, n.º 9, pp. 3489–3510, 2016. DOI: 10.1007/s11227-015-1615-5
- [12] T. Saranya, S. Sridevi, C. Deisy, T. D. Chung e M. K. A. A. Khan, “Performance Analysis of Machine Learning Algorithms in Intrusion Detection System: A Review,” *Procedia Computer Science*, vol. 171, pp. 1251–1260, 2020. DOI: 10.1016/j.procs.2020.04.133
- [13] S. A. R. Shah e B. Issac, “Performance comparison of intrusion detection systems and application of machine learning to Snort system,” *Future Generation Computer Systems*, vol. 80, pp. 157–170, 2018. DOI: 10.1016/j.future.2017.10.016
- [14] K. A. Taher, B. M. Y. Jisan, Md. e M. Rahman, “Network Intrusion Detection using Supervised Machine Learning Technique with Feature Selection,” 2019. DOI: 10.1109/2019.0644161
- [15] A. Thakkar e R. Lohiya, “A survey on intrusion detection system: feature selection, model, performance measures, application perspective, challenges, and future research directions,” *Artificial Intelligence Review*, vol. 54, pp. 4529–4593, 2021. DOI: 10.1007/s10462-021-10037-9

### Agradecimentos

Agradecemos, primeiramente, às nossas famílias, pelo apoio incondicional, incentivo constante e compreensão ao longo de toda a nossa trajetória acadêmica. Sem esse suporte, a realização deste trabalho não seria possível.

Como inspiração para seguir em frente diante dos desafios, destacamos a frase de Walt Disney: “Todos os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los”.