

Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

¹ **Lucas Kerr do Amaral**, ² **Marcela Nalesso**

¹ *Ciência da Computação – FEI* ² *Ciência da Computação – FEI*

¹ *lamaral2002@gmail.com*, ² *marcelanalesso@gmail.com*

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira *laferreira@fei.edu.br*

Resumo: Diante da insuficiência performática em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via Principal Component Analysis (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

Palavras-chaves: IDS, Machine Learning, Segurança

1. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Com o aumento do volume de dados trafegados e da complexidade das infraestruturas, observa-se também um crescimento expressivo na quantidade e sofisticação dos ataques, como negações de serviço, varreduras de rede e acessos não autorizados. Esse cenário evidencia a necessidade de mecanismos eficazes de monitoramento e proteção, capazes de identificar comportamentos maliciosos em tempo hábil. Nesse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de Machine Learning tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender exclusivamente de regras pré-definidas. No entanto, a

eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD e UNSW-NB15 têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a Principal Component Analysis (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de

forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de Machine Learning aplicadas à detecção de intrusões, identificando atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de Principal Component Analysis (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em Machine Learning, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

II. Formatação da página

As margens da folha estão definidas na Tabela I. O trabalho deve conter resumo; introdução; objetivos, metodologia; resultados e conclusões além de

eventuais referências bibliográficas. Seções adicionais podem ser incluídas, caso necessário.

O corpo do trabalho deve ser escrito com caracteres de tamanho 10, sem linhas em branco separando os parágrafos. Em cada novo parágrafo, o início da primeira linha deve ser deslocado em 0,5 cm, conforme modelo. Cabeçalho e rodapé não devem ser alterados.

As referências devem ser indicadas entre chaves [1] ao longo do texto e descrito no final do artigo citando: nomes dos autores (pode ser abreviado, no máximo três nomes e caso tenha mais nomes usar o et. al.), nome da revista, volume, ano da publicação e página ou nome do livro, editor e ano de publicação. Por exemplo: em [2] foram realizados muitos testes, alcançando uma acurácia de 100%. Já em [1] não obtiveram resultados satisfatórios.

III. Figuras, tabelas e equações

A. Figuras

As figuras devem ser centralizadas, e as legendas devem ser numeradas sequencialmente, alinhadas à esquerda na parte inferior, conforme exemplo apresentado, usando fonte Arial tamanho 9. O tamanho da figura e das letras dentro das figuras deve estar legível. Cores podem ser utilizadas, desde que apresentem boa resolução. As figuras devem ser citadas no texto, por exemplo, a Figura 1 apresenta um gráfico.




Figura 1. Legenda da figura dentro da coluna

B. Tabelas

As tabelas devem ser referenciadas sequencialmente, com a legenda posicionada na parte superior da mesma e alinhada à esquerda, usando fonte Arial tamanho 9. **O texto nas células da tabela deve ser centralizado. Usar o comando |c|** Elas devem ser citadas no texto, por exemplo a Tabela I apresenta as informações das margens.

Tabela I. Legenda da tabela, precisa ser intuitivo.

Margem	Tamanho (cm)
Superior	2,0
Inferior	2,0
Esquerda	2,0
Direita	2,0
Coluna	1,0

C. Equações

Caso seja necessário incluir equações, estas devem ser apresentadas em itálico, alinhadas à esquerda, e numeradas no lado direito entre parênteses.

$$W = \theta_1 - \theta_2 \quad (1)$$

IV. Conclusões

Destaque os principais resultados alcançados e contribuições do trabalho desenvolvido.

V. Referências

- [1] A. N. Balaji e L.-S. Peh, “AI-On-Skin: Towards Enabling Fast and Scalable On-body AI Inference for Wearable On-Skin Interfaces,” *Proc. ACM Hum.-Comput. Interact.*, vol. 7, n.º EICS, jun. de 2023. DOI: 10.1145/3593239 URL: <https://doi-org.ez328.periodicos.capes.gov.br/10.1145/3593239>
- [2] J. Jiang, E. Wu e Z. Miao, “Research on the Application of Artificial Intelligence (AI) in Customized Cosmetics Enterprises in South Korea,” em *Proceedings of the 5th International Conference on Artificial Intelligence and Computer Engineering*, sér. ICAICE '24, Association for Computing Machinery, 2025, pp. 485–488, ISBN: 9798400718007. DOI: 10.1145/3716895.3716981 URL: <https://doi-org.ez328.periodicos.capes.gov.br/10.1145/3716895.3716981>

Agradecimentos

A seção de agradecimentos é opcional. **Autores (incluindo o professor orientador) não devem ser incluídos nos agradecimentos.**