

Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

¹ **Lucas Kerr do Amaral**, ² **Marcela Nalesso**

¹ *Ciência da Computação – FEI* ² *Ciência da Computação – FEI*

¹ *lamaral2002@gmail.com*, ² *marcelanalesso@gmail.com*

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira *laferreira@fei.edu.br*

Resumo: Diante da insuficiência performativa em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via *Principal Component Analysis* (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

Palavras-chaves: Sistemas de Detecção de Intrusões, Machine Learning, Segurança da Informação, Análise de Dados, Redução de Dimensionalidade e Cybersegurança.

1. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Com o aumento do volume de dados trafegados e da complexidade das infraestruturas, observa-se também um crescimento expressivo na quantidade e sofisticação dos ataques, como negações de serviço, varreduras de rede e acessos não autorizados. Esse cenário evidencia a necessidade de mecanismos eficazes de monitoramento e proteção, capazes de identificar comportamentos maliciosos em tempo hábil. Nesse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de *Machine Learning* tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender

exclusivamente de regras pré-definidas. No entanto, a eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD e UNSW-NB15 têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a *Principal Component Analysis* (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de *Machine Learning* aplicadas à detecção de intrusões, identificando

atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de *Principal Component Analysis* (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em *Machine Learning*, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

II. Fundamentação Teórica

A. Segurança da Informação e Ameaças em Redes

A segurança da informação tornou-se um elemento central na sociedade contemporânea devido à crescente dependência de sistemas digitais. Com a consolidação da chamada “civilização cibernética”, iniciada a partir da revolução digital no final do século XX, houve um aumento significativo na produção e circulação de dados, ampliando a superfície de ataque para agentes maliciosos **10.1109/2019.8644161**. Dados recentes indicam que o tráfego global per capita evoluiu de 16 GB mensais em 2017 para projeções superiores a 50 GB em

2022, enquanto mais de 14 bilhões de registros foram comprometidos desde 2013, evidenciando a magnitude das ameaças digitais **10.1109/2023.3296444 10.1007/10462-021-10037-9**. Nesse contexto, a Segurança da Informação fundamenta-se na preservação da tríade confidencialidade, integridade e disponibilidade, tornando-se essencial para a proteção de ativos digitais em ambientes cada vez mais interconectados **10.1016/2023.10031 10.1109/2023.3296444 10.1016/2012.09.004**.

A evolução das ameaças cibernéticas acompanha diretamente o avanço tecnológico, tornando os ataques mais sofisticados e diversificados. Entre os principais tipos de ataques identificados na literatura estão os ataques de negação de serviço (DoS), varreduras de rede (Probe), acessos remotos não autorizados (R2L) e escalonamento de privilégios (U2R), cada um explorando vulnerabilidades específicas dos sistemas **10.1016/2023.10031**. Além disso, observa-se o crescimento expressivo dos ataques de dia zero, que exploram falhas ainda desconhecidas, dificultando a detecção por mecanismos tradicionais. Dessa forma, a complexidade e o volume das ameaças exigem soluções capazes de operar em ambientes de grande escala e alta velocidade.

No presente, mais de 61% das interações industriais e sociais ocorrem em ambiente online, o que torna a rede um alvo estratégico para cibercrimes que agora visam não apenas usuários finais, mas diretamente infraestruturas críticas e instituições bancárias. Essa dependência tecnológica exige que os Sistemas de Detecção de Intrusão (IDS) evoluam proporcionalmente à sofisticação das ameaças **10.1016/2023.10031**.

B. Sistemas de Detecção de Intrusão

Os Intrusion Detection System constituem uma das principais ferramentas para monitoramento e identificação de atividades maliciosas em redes. Desde o primeiro modelo formal proposto em 1987, os IDS evoluíram de abordagens estatísticas simples para sistemas inteligentes capazes de analisar grandes volumes de dados em tempo real **10.1109/2019.8644161**. Esses sistemas atuam como uma camada adicional de segurança, monitorando eventos e gerando alertas quando comportamentos suspeitos são identificados. Assim, os IDS desempenham papel fundamental na mitigação de ataques e na proteção de infraestruturas críticas.

Os IDS podem ser classificados tanto pela fonte de dados quanto pela abordagem de detecção. Em relação à origem das informações, destacam-se os sistemas baseados em rede (NIDS) e os baseados em host (HIDS) **10.1109/2023.3296444 10.1016/2020.04.113**, enquanto, quanto à técnica utilizada, dividem-se em sistemas baseados em assinatura (SIDS) e baseados em anomalia (AIDS) **10.1186/42400-019-0038-7 10.1007/10462-021-10037-9**.

10.1016/2022.03.029. Os sistemas baseados em assinatura são eficazes na identificação de ataques conhecidos, porém incapazes de detectar ameaças inéditas, como ataques de dia zero **10.1109/2023.3296444 10.1109/2019.8644161.** Por outro lado, os sistemas baseados em anomalia apresentam maior flexibilidade, mas sofrem com altas taxas de falsos positivos, o que impacta diretamente sua aplicabilidade prática **10.1007/10462-021-10037-9 10.1016/2017.10.016.**

A literatura destaca que os IDS enfrentam desafios significativos relacionados ao volume e à complexidade dos dados de rede. Com o crescimento exponencial do tráfego e a geração massiva de dados, os sistemas tradicionais tornam-se incapazes de processar informações em tempo real sem perda de desempenho. Além disso, a presença de atributos redundantes e irrelevantes nos datasets compromete a eficiência dos modelos de detecção. Esse cenário evidencia a necessidade de soluções mais inteligentes e adaptativas, capazes de lidar com ambientes de Big Data.

C. Machine Learning aplicado à detecção de intrusão

O Machine Learning surge como uma abordagem promissora para superar as limitações dos IDS tradicionais. Ao permitir que sistemas aprendam padrões diretamente dos dados, o aprendizado de máquina possibilita a identificação de comportamentos anômalos e a adaptação a novos tipos de ataques **10.1016/2015.04.191 10.1016/2020.04.113 10.1186/42400-019-0038-7.** Estudos recentes apontam um crescimento significativo no uso de técnicas de ML e Deep Learning na detecção de intrusões, especialmente a partir de 2018. Dessa forma, o ML se consolida como um componente essencial para o desenvolvimento de IDS mais eficientes.

Entre os paradigmas de aprendizado, o modelo supervisionado destaca-se como o mais utilizado na literatura **10.1109/2019.8644161 10.1186/42400-019-0038-7.** Essa abordagem utiliza dados previamente rotulados para treinar modelos capazes de classificar o tráfego de rede como normal ou malicioso. A disponibilidade de bases de dados como NSL-KDD e CICIDS-2017 favorece a aplicação desse tipo de técnica, permitindo comparações padronizadas entre diferentes modelos. Assim, o aprendizado supervisionado torna-se a base para a construção de sistemas de detecção mais precisos.

Entretanto, a aplicação de ML em IDS enfrenta desafios relacionados à alta dimensionalidade dos dados. A presença de atributos redundantes aumenta o custo computacional e pode reduzir a acurácia dos modelos. Nesse contexto, técnicas de seleção de atributos tornam-se essenciais para identificar características relevantes e reduzir a complexidade do sis-

tema. A literatura demonstra que é possível reduzir significativamente o número de atributos sem perda de desempenho, melhorando a eficiência dos modelos **10.1007/10994-014-5473-9.**

D. Algoritmos de classificação

Diversos algoritmos de classificação têm sido aplicados na detecção de intrusões, cada um apresentando vantagens e limitações específicas. Entre os mais utilizados destacam-se o Random Forest, o Support Vector Machine, o K-Nearest Neighbors, as árvores de decisão e o Naive Bayes. Esses algoritmos diferem em termos de desempenho, complexidade computacional e capacidade de generalização. Dessa forma, a escolha do modelo adequado depende diretamente das características do conjunto de dados e do problema abordado.

O Random Forest destaca-se pela alta acurácia e robustez, alcançando taxas superiores a 99% em bases como KDD Cup 99 e NSL-KDD **10.1007/10207-023-00682-2 10.1016/2016.06.016.** Esse algoritmo utiliza múltiplas árvores de decisão para reduzir o risco de sobreajuste. Por outro lado, o SVM apresenta bom desempenho em espaços de alta dimensionalidade, embora sua eficiência dependa fortemente da escolha dos parâmetros **10.1007/10207-023-00682-2 10.1109/2023.3296444 10.1016/2017.10.016.** Assim, ambos os algoritmos são amplamente utilizados em cenários de detecção de intrusão.

Outros algoritmos também desempenham papel relevante na literatura. O KNN destaca-se pela simplicidade, mas possui alto custo computacional na fase de classificação, enquanto as árvores de decisão oferecem interpretabilidade, sendo úteis para análise de regras **10.1007/10207-023-00682-2 10.1186/42400-019-0038-7 10.1109/2023.3296444.** Já o Naive Bayes apresenta boa eficiência computacional, embora sua suposição de independência entre atributos possa limitar seu desempenho **10.1007/10207-023-00682-2 10.1186/42400-019-0038-7 10.1007/11227-015-1615-5.** Dessa forma, a combinação de diferentes algoritmos, por meio de técnicas ensemble, tem sido explorada para melhorar os resultados.

Estudos indicam que a integração entre algoritmos de classificação e técnicas de seleção de atributos é fundamental para alcançar alto desempenho em IDS **10.1007/10207-023-00682-2 10.1186/40537-018-0145-4.** A redução de dimensionalidade permite diminuir o custo computacional e aumentar a velocidade de processamento, especialmente em redes de alta velocidade. Além disso, a escolha adequada de atributos contribui diretamente para a melhoria da acurácia e redução de falsos positivos **10.1007/10994-014-5473-9.** Assim, a combinação dessas técnicas representa uma abordagem

eficaz para a construção de sistemas de detecção mais robustos.

E. Análise de Dados e Pré-processamento

F. Redução de Dimensionalidade e Seleção de Atributos

G. Base de Dados NSL-KDD e UNSW-NB15

H. Métricas de Avaliação

III. Metodologia

IV. Cronograma

Etapas	2026				
	Fev	Mar	Abr	Mai	Jun
Pesquisa para conhecimento do público-alvo	X	X			
Pesquisa de opinião sobre o público-alvo		X	X		
Desenvolvimento do projeto			X	X	
Testes e validação				X	X
Finalização do TCC					X

V. Resultados Parciais

VI. Considerações Finais e Perspectivas Futuras

Nesta primeira etapa foi definido o algoritmo de machine learning utilizado e feitas as análises dos componentes para definição dos componentes mais importantes

VII. Referências

testando bibliografia [1]

- [1] A. Khraisat, I. Gondal, P. Vamplew, J. Kamruzzaman e A. Alazab, “Hybrid Intrusion Detection System Based on the Stacking Ensemble of C5 Decision Tree Classifier and One Class Support Vector Machine,” 2020. DOI: 10.3390/90101173

Agradecimentos

Agradecemos, primeiramente, às nossas famílias, pelo apoio incondicional, incentivo constante e compreensão ao longo de toda a nossa trajetória acadêmica. Sem esse suporte, a realização deste trabalho não seria possível.

Como inspiração para seguir em frente diante dos desafios, destacamos a frase de Walt Disney: “Todos os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los”.