

# Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores: Uma Pesquisa Exploratória e Experimental

<sup>1</sup> Lucas Kerr do Amaral, <sup>2</sup> Marcela Nalesso

<sup>1</sup> Ciência da Computação – FEI <sup>2</sup> Ciência da Computação – FEI

<sup>1</sup> lamaral2002@gmail.com, <sup>2</sup> marcelanalesso@gmail.com

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira laferreira@fei.edu.br

**Resumo:** Diante da insuficiência performática em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via *Principal Component Analysis* (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

**Palavras-chaves:** Sistemas de Detecção de Intrusões, Machine Learning, Seguranças da Informação, Análise de Dados, Redução de Dimensionalidade e Cybersegurança.

## I. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Esse crescimento é acompanhado por um aumento expressivo no volume de dados trafegados, que passou de aproximadamente 16 GB por usuário ao mês em 2017 para cerca de 50 GB mensais em 2022 **Thakkar2021Survey**. Esse cenário contribui diretamente para a ampliação da superfície de ataque, refletindo no aumento da quantidade e da sofisticação de ameaças, como negações de serviço, varreduras de rede e acessos não autorizados. Paralelamente, os impactos de falhas de segurança tornam-se cada vez mais críticos, sendo que mais de 14 bilhões de registros de dados foram vazados desde 2013, além de prejuízos financeiros significativos, como os 29,8 bilhões de dólares perdidos em golpes telefônicos apenas no ano de 2020 **zehedi2023comparative**. Diante desse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos

cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de *Machine Learning* tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender exclusivamente de regras pré-definidas. No entanto, a eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a *Principal Component Analysis* (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos

existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de *Machine Learning* aplicadas à detecção de intrusões, identificando atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de *Principal Component Analysis* (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em *Machine Learning*, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

## II. Fundamentação Teórica

### A. Segurança da Informação e Ameaças em Redes

A segurança da informação tornou-se um elemento central na sociedade contemporânea devido à crescente dependência de sistemas digitais. Com a consolidação da chamada “civilização cibernética” **wasyhun2023cyber**, iniciada a partir da revolução digital no final do século XX **Kazi2019network**, houve um aumento significativo na produção e circulação de dados, ampliando a superfície de ataque para agentes maliciosos. Nesse cenário, a segurança mostra-se indispensável, sobretudo pelo uso intensivo de sistemas digitais em setores críticos como bancos, saúde, governo e educação, nos quais a proteção das informações é fundamental para garantir a continuidade dos serviços, a confiabilidade das operações e a segurança da sociedade como um todo **wasyhun2023cyber**.

É desta forma que o foco central da área de pesquisa é proteger dados contra ameaças internas e externas, assegurando a tríade da confidencialidade, integridade e disponibilidade (CIA) de forma eficiente e com o menor custo possível **diptiben2022cyber**. Nesse contexto, evidencia-se que ataques cibernéticos representam riscos significativos para as organizações, podendo ocasionar perdas financeiras expressivas, danos à reputação institucional e até impactos críticos, inclusive fatais, quando afetam infraestruturas essenciais **wasyhun2023cyber**. Além disso, observa-se que organizações estão constantemente sob ataques direcionados, o que reforça a complexidade e a frequência dessas ameaças no ambiente digital contemporâneo **diptiben2022cyber**. Dessa forma, torna-se imprescindível a adoção de estratégias robustas de segurança da informação, capazes de mitigar riscos e garantir a proteção contínua dos ativos informacionais diante de um cenário cada vez mais hostil.

As ameaças em redes de computadores apresentam diversidade e complexidade, sendo classificadas em diferentes categorias conforme seu objetivo e forma de atuação. Entre as principais estão os ataques de negação de serviço (DoS), que visam indisponibilizar recursos, ataques de sondagem (probing), que coletam informações da rede, além de técnicas de escalonamento de privilégios (U2R) e acesso remoto indevido (R2L) **wasyhun2023cyber**. Além dessas categorias, destacam-se ameaças modernas como malware, botnets e ataques de engenharia social, que exploram vulnerabilidades técnicas e humanas **Thakkar2021Survey solane2015using**. Essa variedade evidencia que os sistemas precisam lidar não apenas com ataques diretos, mas também com estratégias sofisticadas de invasão e evasão. Portanto, a classificação das ameaças é fundamental para orientar mecanismos de detecção e defesa mais eficientes.

Um dos maiores desafios atuais da segurança em redes está relacionado aos ataques de dia zero, que exploram vulnerabilidades ainda desconhecidas

pelos sistemas de defesa. Por não possuírem assinaturas previamente registradas, esses ataques são difíceis de identificar por métodos tradicionais, funcionando como ameaças invisíveis até que sejam descobertas **wasyhun2023cyber**. Casos reais, como a Operação Aurora, demonstram o potencial destrutivo dessas ameaças, incluindo roubo de dados sensíveis e comprometimento de infraestruturas críticas **wasyhun2023cyber**. Além disso, o aumento significativo desse tipo de ataque nos últimos anos reforça a necessidade de abordagens mais avançadas de detecção. Dessa forma, a evolução das ameaças exige a adoção de soluções mais inteligentes e adaptativas.

Nesse contexto, os Sistemas de Detecção de Intrusão (IDS) desempenham um papel central na proteção de redes, sendo responsáveis por monitorar atividades e identificar comportamentos suspeitos. Esses sistemas permitem a detecção precoce de ataques, possibilitando ações de mitigação antes que danos maiores ocorram. No entanto, ainda apresentam limitações importantes, como altas taxas de falsos positivos e dificuldade na identificação de ataques desconhecidos **emad2022intrusion**. Tais limitações evidenciam a necessidade de evolução desses mecanismos, especialmente com o uso de técnicas mais avançadas, como aprendizado de máquina, capazes de analisar padrões complexos e melhorar a eficiência da detecção **patrick2022study**. Assim, o aprimoramento dos IDS é fundamental para enfrentar os desafios contemporâneos da segurança em redes.

### B. Sistemas de Detecção de Intrusão

Os Sistemas de Detecção de Intrusão (IDS) são fundamentais para a segurança de redes, pois monitoram atividades suspeitas e identificam possíveis ataques por meio da análise de tráfego e comportamento. Esses sistemas podem ser implementados em hardware ou software e realizam funções como geração de alertas e resposta a incidentes. O conceito de IDS surgiu na década de 1980, inicialmente baseado na análise de logs e padrões conhecidos, o que limitava sua eficácia frente a ameaças mais complexas. Com o avanço dos ataques, os IDS evoluíram para abordagens mais dinâmicas, incorporando análise comportamental e, posteriormente, técnicas de detecção por anomalias na década de 1990, permitindo a identificação de ataques desconhecidos **patrick2022study**. Dessa forma, os IDS consolidaram-se como mecanismos essenciais para a proteção de ativos digitais e mitigação de ameaças em redes **emad2022intrusion**.

Os IDS podem ser classificados de acordo com sua forma de implantação e método de detecção, o que influencia diretamente sua eficiência. Quanto à implantação, destacam-se os sistemas baseados em host (HIDS), que monitoram atividades locais, e os baseados em rede (NIDS), que analisam o tráfego em pontos estratégicos da infraestrutura. Já em relação ao método de detecção, os IDS podem

operar por meio de assinaturas, identificando padrões conhecidos de ataques, ou por anomalias, detectando desvios em relação ao comportamento considerado normal. Além disso, abordagens híbridas combinam essas técnicas para superar limitações individuais **Khraisat2019Survey zehedi2023comparative Thakkar2021Survey Khraisat2019Hybrid**. Essa diversidade de classificações demonstra a necessidade de adaptar os mecanismos de detecção conforme o contexto e os tipos de ameaças enfrentadas. Portanto, a escolha do tipo de IDS deve considerar os requisitos específicos do ambiente.

Apesar de sua relevância, os IDS ainda apresentam limitações significativas que comprometem sua eficácia. Sistemas baseados em assinatura, por exemplo, são incapazes de identificar ataques desconhecidos, como os de zero-day, enquanto sistemas baseados em anomalias podem gerar altas taxas de falsos positivos ao interpretar comportamentos legítimos como ameaças **Kazi2019network**. Além disso, muitos IDS enfrentam desafios relacionados ao alto custo computacional, datasets mais modernos e à dificuldade de operar em tempo real em ambientes com grande volume de tráfego. Essas limitações evidenciam que, embora essenciais, os IDS tradicionais ainda não são totalmente suficientes para lidar com a complexidade das ameaças modernas **emad2022intrusion patrick2022study**. Dessa forma, torna-se necessário aprimorar continuamente esses sistemas.

### C. Machine Learning aplicado à detecção de intrusão

O uso de Machine Learning (ML) tem se consolidado como uma abordagem fundamental para aprimorar os Sistemas de Detecção de Intrusão (IDS), permitindo a análise automatizada de grandes volumes de dados de rede. Diferentemente dos métodos tradicionais, o ML possibilita a identificação de padrões complexos e a detecção de atividades maliciosas sem a necessidade de intervenção humana constante. Isso ocorre porque os modelos são capazes de aprender a partir de dados históricos, tornando os sistemas mais adaptativos e eficientes na identificação de ameaças **zehedi2023comparative Thakkar2021Survey**. Dessa forma, o ML amplia significativamente a capacidade dos IDS em lidar com ambientes dinâmicos e com grande volume de tráfego. Assim, sua aplicação representa um avanço importante na evolução das soluções de segurança de redes.

As técnicas de Machine Learning aplicadas aos IDS podem ser classificadas em diferentes abordagens, sendo as mais comuns o aprendizado supervisionado, não supervisionado e por reforço. No aprendizado supervisionado, os modelos são treinados com dados previamente rotulados, permitindo a classificação do tráfego como normal ou malicioso, enquanto o aprendizado não supervisionado busca identificar padrões ocultos sem a necessidade de rótulos. Além disso, o processo de construção

desses modelos envolve a divisão dos dados em conjuntos de treinamento e teste, garantindo a avaliação do desempenho do sistema **zehedi2023comparative emad2022intrusion**. Essa diversidade de abordagens permite que os IDS sejam adaptados a diferentes cenários e tipos de ataque, aumentando sua flexibilidade e eficiência. Portanto, a escolha da técnica de aprendizado influencia diretamente a eficácia da detecção de intrusões.

Entre os principais benefícios do uso de ML em IDS está a capacidade de detectar ataques desconhecidos, como os zero-day, além de lidar com relações complexas e não lineares presentes nos dados de rede. No entanto, essa abordagem também apresenta desafios relevantes, como o alto custo computacional e o tempo elevado de treinamento. Outro problema recorrente é o desbalanceamento dos dados, que dificulta a detecção de ataques menos frequentes, impactando negativamente o desempenho dos modelos. Essas limitações evidenciam que, embora o ML traga avanços significativos, sua aplicação ainda exige cuidados na preparação e tratamento dos dados **zehedi2023comparative**. Dessa forma, o sucesso do uso de ML em IDS depende não apenas dos algoritmos, mas também da qualidade dos dados utilizados.

Além disso, etapas como pré-processamento, seleção de atributos e redução de dimensionalidade são essenciais para garantir o desempenho dos modelos de Machine Learning em IDS. A limpeza dos dados, normalização e codificação de variáveis contribuem para a construção de modelos mais robustos, enquanto técnicas como seleção de atributos e métodos como PCA ajudam a reduzir a complexidade dos dados e melhorar a acurácia. Para avaliar a eficácia dos modelos, são utilizadas métricas como acurácia, precisão, recall e F1-score, que permitem analisar o equilíbrio entre a detecção de ataques e a geração de falsos positivos. Assim, a integração entre boas práticas de tratamento de dados e algoritmos de ML é fundamental para o desenvolvimento de IDS mais eficientes e confiáveis **zehedi2023comparative Thakkar2021Survey**. Portanto, o uso estruturado dessas técnicas potencializa os resultados obtidos na detecção de intrusões.

#### D. Algoritmos de classificação

##### D.1 Visão Geral

A diversidade de algoritmos utilizados em sistemas de detecção de intrusão é destacada no trabalho de **Liao2013Intrusion**, que realiza uma revisão abrangente das técnicas de IDS, incluindo métodos baseados em Bayes, teoria dos jogos e mineração de dados. O estudo evidencia que algoritmos de mineração, como árvores de decisão, e métodos como SVM apresentam altas taxas de acurácia na detecção de ataques. Esses resultados indicam que não existe

uma abordagem única dominante, mas sim um conjunto de técnicas complementares que podem ser utilizadas conforme o contexto da aplicação.

A aplicação de algoritmos supervisionados em ambientes modernos é analisada por **Saranya2020Performance**, que investigam o desempenho de diferentes modelos em cenários como IoT e 5G. O estudo compara algoritmos como CART e Random Forest, destacando que o uso de múltiplas árvores (ensemble) resulta em melhor desempenho. Os resultados mostram que o Random Forest atingiu 99,65% de acurácia, superando o CART isolado (98%). Esse achado reforça a importância de abordagens híbridas e ensembles para melhorar a robustez dos modelos.

A integração de diferentes algoritmos também é explorada por **Khraisat2019Hybrid**, que propõem um modelo híbrido combinando C5.0 e One-Class SVM. O estudo utiliza todos os atributos do NSL-KDD para treinamento e demonstra que a combinação entre detecção de assinatura e anomalia melhora a capacidade do sistema. Os resultados mostram acurácia de 83,24% no NSL-KDD e 97,04% no dataset ADFA. Esses resultados evidenciam que a combinação de algoritmos pode superar limitações individuais de cada abordagem.

##### D.2 Ênfase em Árvores de Decisão

A eficiência e interpretabilidade das árvores de decisão são destacadas no estudo de **zehedi2023comparative**, que propõe esse algoritmo como modelo central para detecção de intrusão. O trabalho explora variações como ID3, C4.5 e CART, enfatizando sua estrutura baseada em nós de decisão e ramos. Os resultados mostram que o modelo CART alcançou 97,36% de sucesso em aplicações preditivas. Esse desempenho, aliado à facilidade de interpretação, torna as árvores de decisão altamente relevantes para sistemas que exigem transparência nas decisões.

A robustez das árvores de decisão em arquiteturas híbridas é demonstrada por **Depren2005Intelligent**, que combinam o algoritmo J48 com mapas auto-organizáveis (SOM). O uso de técnicas de poda (pruning) é destacado como estratégia para evitar o overfitting. Os resultados mostram que o sistema alcançou 99,84% precisão na detecção de ataques de uso indevido. Esse resultado evidencia que árvores de decisão, quando bem ajustadas e combinadas com outras técnicas, podem atingir níveis extremamente elevados de desempenho.

A utilização de árvores em modelos ensemble é aprofundada por **Xianwei2019Adaptive**, que propõem o algoritmo MultiTree baseado em múltiplas árvores CART e votação majoritária. O estudo também aborda o problema de desbalanceamento de dados, comum em IDS. Os resultados mostram que o modelo atingiu 85,2% de acurácia em cenários desafi-

adores, superando abordagens isoladas. Esse achado reforça que múltiplas árvores aumentam a capacidade de generalização dos modelos.

A aplicabilidade das árvores de decisão em cenários de alta performance é evidenciada por **Rathore2016RealTime**, que utilizam algoritmos como J48 e REPTree em ambientes de Big Data. Os resultados mostram taxas de verdadeiros positivos superiores a 99,9%, indicando alta eficiência na detecção de intrusões em tempo real. Esse resultado demonstra que árvores de decisão são adequadas para sistemas que exigem rapidez e precisão simultaneamente.

Por fim, **Abdulganiyu2023Systematic** consolida, em sua revisão sistemática, que algoritmos baseados em árvores apresentam acurácia variando entre 85,2% e 99,9%, dependendo do contexto e da preparação dos dados. Esses resultados reforçam que as árvores de decisão são uma das abordagens mais consistentes e versáteis dentro da área de detecção de intrusão, especialmente quando combinadas com técnicas de pré-processamento e seleção de atributos.

#### E. Redução de Dimensionalidade e Seleção de Atributos

A relevância do pré-processamento e da redução de dimensionalidade em sistemas de detecção de intrusão é evidenciada no estudo de **patrick2022study**, que revisa o estado da arte de IDS baseados em inteligência artificial e aprendizado de máquina. O trabalho analisa conjuntos de dados amplamente utilizados, como KDDCup99 e CICIDS2017, destacando o elevado número de atributos (41 e 80, respectivamente) e a necessidade de técnicas como PCA para reduzir essa dimensionalidade. Os resultados mostram que modelos que utilizam essas estratégias, especialmente combinados com deep learning e métodos de ensemble, atingem acurácias entre 94,4% e 99,24%. Esses achados indicam que o pré-processamento não é apenas uma etapa auxiliar, mas um fator determinante para viabilizar o uso de modelos mais complexos em ambientes de IDS.

A importância da engenharia de atributos é aprofundada no estudo de **Thakkar2021Survey**, que investiga técnicas de seleção de atributos e seu impacto no desempenho dos modelos. O trabalho analisa diferentes abordagens, como filtros, wrappers e métodos embutidos, demonstrando que a redução de conjuntos de dados para 5 a 20 atributos relevantes pode melhorar significativamente a eficiência dos algoritmos. Os resultados indicam que, utilizando técnicas como ganho de informação e qui-quadrado, modelos baseados em árvores de decisão podem alcançar até 95,5% de precisão. Esse resultado reforça que a escolha adequada de atributos reduz a complexidade do problema e aumenta a capacidade discriminativa dos modelos.

A eficiência da redução de atributos em cenários de alta demanda computacional é destacada por

**felix2014analysis**, que propõem uma abordagem multiestágio para seleção de características em detecção de anomalias. O estudo reduz progressivamente o conjunto de atributos de 41 para 30 e posteriormente para 16, utilizando técnicas de filtro e regressão stepwise. Os resultados mostram que a acurácia do modelo aumentou de 75,53% para 78,68% após a primeira redução, mantendo-se praticamente estável mesmo com menos atributos. Esses achados evidenciam que é possível reduzir significativamente a dimensionalidade sem perda de desempenho, o que é especialmente relevante para sistemas em tempo real.

A relação entre seleção de atributos e desempenho em ambientes de Big Data é abordada por **Othman2018Intrusion**, que investigam modelos de detecção de intrusão utilizando Apache Spark. O estudo aplica o teste qui-quadrado para selecionar 17 atributos mais relevantes a partir das 41 características do KDD99. Os resultados mostram um AU-ROC de 99,55%, evidenciando alto poder discriminativo mesmo com um conjunto reduzido de atributos. Esse resultado demonstra que a redução de dimensionalidade é essencial não apenas para eficiência computacional, mas também para manter ou até melhorar a qualidade das previsões em ambientes distribuídos.

A importância da seleção de atributos também é reforçada por **Rathore2016RealTime**, que investigam sistemas de detecção de intrusão em ambientes de Big Data de alta velocidade. O estudo identifica que apenas 9 atributos são suficientes para alcançar desempenho superior em classificação, utilizando algoritmos como J48 e REPTree. Os resultados mostram taxas de verdadeiros positivos superiores a 99,9%, indicando que a redução agressiva de atributos pode ser altamente eficaz quando bem direcionada. Esse achado é particularmente relevante para aplicações em tempo real, onde a latência e o custo computacional são fatores críticos.

Além disso, **emad2022intrusion** reforçam, em sua revisão sobre técnicas supervisionadas para IDS, que a seleção de atributos é um dos fatores mais críticos para o desempenho dos modelos. O estudo analisa múltiplos datasets e demonstra que a redução para conjuntos de 10 a 19 atributos é comum em abordagens eficientes. Os resultados indicam que modelos como Random Forest podem atingir até 99,9% de acurácia quando combinados com estratégias adequadas de pré-processamento. Esses achados consolidam a ideia de que a qualidade dos dados é tão importante quanto a escolha do algoritmo.

A fim de organizar e comparar os principais trabalhos<sup>1</sup> relacionados à detecção de intrusões e machine learning, foi elaborada a Tabela I contendo os estudos mais relevantes identificados na literatura.

<sup>1</sup>Arquivo disponível em: [https://1drv.ms/x/c/46f377637be54264/IQB7NxizkmLAS7\\_X22no62qJAZ115FV9\\_5Dt7G3kALLXvTY?e=ypAxe1](https://1drv.ms/x/c/46f377637be54264/IQB7NxizkmLAS7_X22no62qJAZ115FV9_5Dt7G3kALLXvTY?e=ypAxe1)

| Título                    | Citações | Autor              | Ano  | Tipo             | HIDS/NIDS      | Sig.              | Técnica        | Técnica Utilizada                           | Desempenho                | Base                        |
|---------------------------|----------|--------------------|------|------------------|----------------|-------------------|----------------|---------------------------------------------|---------------------------|-----------------------------|
| patrick2022study          | 172      | Vanin et al.       | 2022 | Revisão          | Ambos          | Ambos             | Ambos          | CNN, DNN, SVM, Ensembles                    | 99,24% (Acurácia)         | KDD99, NSL-KDD, CI-CIDS2017 |
| Thakkar2021Survey         | 459      | Thakkar & Lohiya   | 2022 | Pesquisa/Revisão | NIDS           | Ambos             | Ambos          | ML, DL e SWEVO                              | 95,5% (Acurácia)          | KDD99, NSL-KDD, CI-CIDS2017 |
| Abdulganiyu2023Systematic | 30       | Abdulganiyu et al. | 2022 | SLR              | NIDS           | Ambos + Híbrido   | Sup.           | CNN, ANN, RF, SVM, DT                       | CNN+AE (100%)             | KDD99, NSL-KDD, CI-CIDS2017 |
| Depren2005Intelligent     | 803      | Depren et al.      | 2005 | Proposta         | NIDS           | Híbrido           | Ambos          | SOM (N. Sup.) e J.48 (Sup.)                 | 99,84% (Uso Indevido)     | KDD Cup 99                  |
| Xianwei2019Adaptive       | 696      | Gao et al.         | 2019 | Proposta         | NIDS           | Anomalia          | Supervisionada | Ensemble (DT, RF, KNN, DNN)                 | 85,2% (Acurácia)          | NSL-KDD                     |
| felix2014analysis         | 293      | Iglesias & Zseby   | 2015 | Análise          | NIDS           | Anomalia          | Supervisionada | DTC, kNN, NB, ANN, SVM                      | 78,68% (Acurácia)         | NSL-KDD                     |
| zehedi2023comparative     | 319      | Azam et al.        | 2023 | Revisão          | NIDS           | Híbrido           | Supervisionada | DT (C4.5, ID3, CART)                        | 97,36% (Acurácia)         | NSL-KDD, ADFA, KDD99        |
| diptiben2022cyber         | 253      | Ghelani et al.     | 2022 | Visão Geral      | NIDS/Ciberseg. | Geral             | Plataforma IA  | Geral ML/DL                                 | Qualitativo               | Bibliográfica               |
| wasyhun2023cyber          | 466      | Admass et al.      | 2024 | Revisão          | Geral          | Geral             | Ambos          | ML/DL                                       | Síntese de Estado da Arte | EHR (Tempo Real)            |
| Khraisat2019Hybrid        | 256      | Khraisat et al.    | 2020 | Proposta         | Ambos          | Híbrido           | Supervisionada | Stacking (C5.0 + One-Class SVM)             | 97,04% (ADFA)             | NSL-KDD, ADFA               |
| Jabez2015Intrusion        | 365      | Jabez & Muthukumar | 2015 | Proposta         | NIDS           | Anomalia          | Não Sup.       | NOF (Outlier Detection)                     | Tempo de CPU superior     | KDD Cup 99                  |
| Othman2018Intrusion       | 305      | Othman et al.      | 2018 | Proposta         | NIDS           | Anomalia          | Supervisionada | SVMWithSGD (Spark)                          | 99,55% (AUROC)            | KDD Cup 99                  |
| Liao2013Intrusion         | 2463     | Liao et al.        | 2013 | Revisão          | Vários         | AD, SD, SPA       | Vários         | Bayes, Game Theory, Data Mining             | Alta Acurácia (em SVM/DM) | KDD Cup 99                  |
| Kazi2019Network           | 327      | Taher et al.       | 2019 | Estudo de Caso   | NIDS           | Anomalia          | Supervisionada | SVM e ANN                                   | 94,02% (Acurácia)         | NSL-KDD                     |
| Saranya2020Performance    | 555      | Saranya et al.     | 2020 | Revisão/Prop.    | Ambos          | Ambos + Hib.      | Supervisionada | LDA, CART, RF                               | 99,81% (Acurácia)         | KDD-CUP                     |
| Shah2018Performance       | 332      | Shah & Issac       | 2018 | Estudo Comp.     | NIDS (Snort)   | Híbrido           | Supervisionada | SVM, DT, Fuzzy, Naive Bayes                 | SVM superior              | Snort logs, DARPA, NSL-KDD  |
| Belavagi2016Performance   | 482      | Belavagi & Muniyal | 2016 | Estudo de Caso   | NIDS           | Anomalia/Usu Ind. | Supervisionada | LR, SVM, GNB, RF                            | 99% (Acurácia)            | NSL-KDD                     |
| Rathore2016RealTime       | 147      | Rathore et al.     | 2017 | Proposta         | NIDS           | Anomalia          | Supervisionada | REPTree, J48, SVM, NB                       | 99% (Taxa Ver. Pos.)      | DARPA, KDD99, NSL-KDD       |
| Khraisat2019Survey        | 256      | Khraisat et al.    | 2020 | Proposta         | Ambos          | Híbrido           | Supervisionada | Stacking (C5.0 + One-Class SVM)             | 97,04% (ADFA)             | NSL-KDD, ADFA               |
| solane2015using           | 175      | Duque & Omar       | 2015 | Proposta         | NIDS context   | Anomalia          | Não Sup.       | K-means (Clustering)                        | 81,61% (Eficiência)       | NSL-KDD                     |
| emad2022intrusion         | 175      | Abdallah et al.    | 2022 | Pesquisa         | NIDS focus     | Anomalia/Usu Ind. | Supervisionada | RF, SVM, LR, GNB, J48, DNN                  | 99,9% (Acurácia em RF)    | KDD99, NSL-KDD, CI-CIDS2017 |
| James2023Introduction     | 1879     | James et al.       | 2023 | Estudo Didático  | Não se aplica  | Não se aplica     | Ambos          | LR, DT, SVM, RF, KNN, PCA, K-means e outros | Não se aplica             | Bases didáticas             |

**Tabela I.** Revisão dos trabalhos sobre IDS

### III. Cronograma

#### 1. Janeiro

- Levantamento Inicial da Área de Pesquisa:** Realização de estudos introdutórios sobre a área de Segurança da Informação, com foco em Intrusion Detection Systems (IDS) e aplicação de técnicas de Machine Learning na detecção de ameaças cibernéticas.

#### 2. Fevereiro

- Continuidade do Levantamento Teórico da Área:** Aprofundamento da pesquisa introdutória, visando consolidar o entendimento sobre redes de computadores, segurança cibernética e métodos de detecção de intrusões.
- Definição do Tema de Pesquisa:** Delimitação do escopo do Trabalho de Conclusão de Curso, estabelecendo o foco na utilização de técnicas de aprendizado de máquina aplicadas à detecção de intrusões em redes computacionais.
- Entrega do Checklist do TCC:** Organização e submissão da documentação inicial exigida para formalização e acompanhamento do desenvolvimento do Trabalho de Conclusão de Curso.

#### 3. Março

- Pesquisa e Seleção de Referências Bibliográficas:** Levantamento de artigos

científicos, trabalhos acadêmicos e materiais técnicos relacionados à detecção de intrusões, pré-processamento de dados e algoritmos de Machine Learning aplicados à cibersegurança.

- Levantamento e Seleção das Bases de Dados:** Análise e escolha das bases de dados utilizadas no projeto, incluindo a NSL-KDD para o desenvolvimento inicial, além das bases UNSW-NB15 e CICIDS2017 previstas para utilização em etapas futuras do MVP.
- Estudo de Técnicas de Pré-Processamento e Extração de Características:** Pesquisa sobre métodos de tratamento e redução de dimensionalidade dos dados, incluindo técnicas como PCA (Principal Component Analysis), matriz de correlação e extração de features relevantes para otimização dos modelos.
- Pesquisa sobre Algoritmos de Machine Learning:** Estudo dos principais algoritmos supervisionados e não supervisionados aplicáveis à detecção de intrusões, analisando características, vantagens e limitações de cada abordagem.

#### 4. Abril

- Levantamento de Dados Analíticos para Fundamentação do Tema:** Coleta e análise de informações estatísticas e estudos recentes que evidenciam o crescimento das ameaças cibernéticas e a relevância da

utilização de sistemas inteligentes de detecção de intrusão.

- (b) **Elaboração das Referências Bibliográficas:** Estruturação e organização das referências utilizadas no trabalho, seguindo as normas acadêmicas exigidas.
- (c) **Desenvolvimento Inicial Utilizando a Base NSL-KDD:** Realização de estudos práticos envolvendo pré-processamento de dados, aplicação de algoritmos supervisionados e análise de métricas de desempenho, como acurácia, precisão, recall e taxa de detecção.

## 5. Maio

- (a) **Definição do Algoritmo Supervisionado Principal:** Escolha do algoritmo supervisionado mais adequado para o desenvolvimento do MVP1, considerando desempenho, capacidade de generalização e resultados obtidos nos testes preliminares.
- (b) **Continuidade do Desenvolvimento com a Base NSL-KDD:** Aprimoramento das etapas de pré-processamento, treinamento e avaliação dos modelos supervisionados aplicados à base de dados NSL-KDD.
- (c) **Sistematização da Revisão Bibliográfica:** Organização e consolidação dos conteúdos teóricos levantados ao longo da pesquisa, estruturando a fundamentação teórica do trabalho.
- (d) **Sistematização dos Resultados do MVP1:** Documentação e análise dos resultados obtidos durante o desenvolvimento do primeiro MVP, destacando métricas de desempenho, limitações e possibilidades de melhoria.
- (e) **Elaboração da Apresentação do Trabalho de Conclusão de Curso:** Desenvolvimento do material de apresentação contendo os principais objetivos, metodologia, resultados parciais e contribuições do projeto.

## 6. Junho

- (a) **Apresentação do Trabalho de Conclusão de Curso:** Apresentação formal do projeto desenvolvido, abordando fundamentação teórica, metodologia aplicada, desenvolvimento do MVP, resultados alcançados e considerações finais do trabalho.

| Etapas | 2026 |     |     |     |     |     |     |     |     |   |
|--------|------|-----|-----|-----|-----|-----|-----|-----|-----|---|
|        | Jan  | Fev | Mar | Abr | Mai | Jun | Jul | Ago | Set | O |
| 1(a)   | X    |     |     |     |     |     |     |     |     |   |
| 2(a)   |      | X   |     |     |     |     |     |     |     |   |
| 2(b)   |      | X   |     |     |     |     |     |     |     |   |
| 2(c)   |      | X   |     |     |     |     |     |     |     |   |
| 3(a)   |      |     | X   |     |     |     |     |     |     |   |
| 3(b)   |      |     | X   |     |     |     |     |     |     |   |
| 3(c)   |      |     | X   |     |     |     |     |     |     |   |
| 3(d)   |      |     | X   |     |     |     |     |     |     |   |
| 4(a)   |      |     |     | X   |     |     |     |     |     |   |
| 4(b)   |      |     |     | X   |     |     |     |     |     |   |
| 4(c)   |      |     |     | X   |     |     |     |     |     |   |
| 5(a)   |      |     |     |     | X   |     |     |     |     |   |
| 5(b)   |      |     |     |     | X   |     |     |     |     |   |
| 5(c)   |      |     |     |     | X   |     |     |     |     |   |
| 5(d)   |      |     |     |     | X   |     |     |     |     |   |
| 5(e)   |      |     |     |     | X   |     |     |     |     |   |
| 6(a)   |      |     |     |     |     | X   |     |     |     |   |

## IV. Resultados Preliminares

### A. Análise de Dados e Pré-processamento

Para a análise de dados foi considerado a base de dados NSL-KDD com os seguintes ataques: *neptune*, *satan*, *ipsweep*, *poetsweep*, *smurf*, *nmap*, *back*, *teardrop*, *warezclient*, *pod*, *guess\_passwd*, *buffer\_overflow*, *warezmaster*, *land*, *imap*, *rootkit*, *loadmodule*, *ftp\_write*, *multihop*, *phf*, *perl*, *spy*. alguns dos valores citados não são ataques reais, porém no contexto desta análise componentes como: *loadmodule*, *perl* e *nmap* foram categorizados como ataques.

|                 |       |
|-----------------|-------|
| normal          | 67343 |
| neptune         | 41214 |
| satan           | 3633  |
| ipsweep         | 3599  |
| portsweep       | 2931  |
| smurf           | 2646  |
| nmap            | 1493  |
| back            | 956   |
| teardrop        | 892   |
| warezclient     | 890   |
| pod             | 201   |
| guess_passwd    | 53    |
| buffer_overflow | 30    |
| warezmaster     | 20    |
| land            | 18    |
| imap            | 11    |
| rootkit         | 10    |
| loadmodule      | 9     |
| ftp_write       | 8     |
| multihop        | 7     |
| phf             | 4     |
| perl            | 3     |
| spy             | 2     |


**Tabela II.** Dados presentes na base NSL-KDD

Para melhor visualização dos dados os ataques foram separados nas seguintes categorias: *normal*, *dos*, *probe*, *r2l*, *u2r*.

| Categoria | Tipos de Ataque                                                                           |
|-----------|-------------------------------------------------------------------------------------------|
| normal    | Normal                                                                                    |
| dos       | Neptune<br>smurf<br>teardrop<br>pod<br>land                                               |
| probe     | nmap<br>ipsweep<br>satan                                                                  |
| r2l       | warezclient<br>warezmaster<br>guess_passwd<br>imap<br>ftp_write<br>multihop<br>phf<br>spy |
| u2r       | buffer_overflow<br>rootkit<br>loadmodule<br>perl                                          |


**Tabela III.** Definição de tipos de ataque por grupos

A matriz de correlação mostra que, a contagem de pacotes e ocorrência de erros são os componentes com maior correlação.



**Figura 1.** Matriz de correlação da base NSL-KDD

Para validar as informações da matriz de correlação foi feita uma análise baseada em *PCA*, plotando um gráfico com os dois primeiros componentes e separando os valores pelos grupos anteriormente mencionados na tabela III.



**Figura 2.** visualização de dois componentes do PCA separado por classes

## B. Redução de Dimensionalidade e Seleção de Atributos

Buscando uma margem de variância a cima de 95% foi calculado o *PCA* para variados números de componentes, para descobrir a melhor variância, com o menor número de componentes. Definido 23 componentes como a melhor média amostral




Figura 3. Variância explicada para PCA




Figura 4. PCA classificando tráfego como ataque e normal

## V. Metodologia

O algoritmo utilizado para as análises foi o *DecisionTree*, este conta com o menor tempo de teste e melhor acurácia, estes valores são a maior métrica utilizada pois o objetivo do sistema é ser executado em tempo real para garantir uma resposta rápida a incidentes.

Utilizando os testes do capítulo anterior, foi desenvolvida uma análise com os variados algoritmos mais utilizados (*RandomForest*, *DecisionTree*, *KNN*, *SVM*, *LogisticRegression*). Utilizando um random state de 42 para os algoritmos citados, obtiveram-se os seguintes valores:

| Modelo | Acc    | Prec   | Rec    | F1     | Tempo Treino(s) | Tempo T |
|--------|--------|--------|--------|--------|-----------------|---------|
| RF     | 0.9987 | 0.9992 | 0.9979 | 0.9985 | 6.3216          | 0.120   |
| DT     | 0.9977 | 0.9975 | 0.9975 | 0.9975 | 0.8541          | 0.000   |
| KNN    | 0.9935 | 0.9921 | 0.9940 | 0.9931 | 0.0052          | 16.56   |
| LR     | 0.9454 | 0.9504 | 0.9313 | 0.9408 | 3.0691          | 0.000   |
| SVM    | 0.9544 | 0.9594 | 0.9418 | 0.9506 | 217.7609        | 9.050   |

Tabela IV. Estatísticas de treino dos modelos

Dados os valores da tabela IV o algoritmo selecionado foi o Decision Tree, dado seu baixo tempo de teste e alta acurácia.

Utilizando os valores anteriormente definidos na figura 2 para uma melhor visualização dos dados que realmente importam, o gráfico foi dividido entre ataques e tráfego normal:

Estudando as features com o auxílio dos resultados do *PCA* chegou-se a Conclusão que com 7 features é possível alcançar uma acurácia com valores a cima de 95%:





Figura 5. Representação da importância de cada feature para a acurácia

Afim de refinar os dados representado no *PCA* pela imagem 5 uma análise similar foi feita utilizando

o algoritmo *DecisionTree*:

os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los”.



**Figura 6.** Features variadas para o decision tree

Indicando que o número ótimo de features é 18, onde a acurácia é maior. Sendo elas:

1. src\_bytes
2. dst\_host\_srv\_count
3. count
4. dst\_bytes
5. dst\_host\_srv\_error\_rate
6. hot
7. dst\_host\_same\_src\_port\_rate
8. logged\_in
9. srv\_count
10. dst\_host\_same\_srv\_rate
11. duration
12. wrong\_fragment
13. dst\_host\_error\_rate
14. dst\_host\_diff\_srv\_rate
15. dst\_host\_count
16. dst\_host\_srv\_diff\_host\_rate
17. dst\_host\_serror\_rate
18. diff\_srv\_rate

## VI. Considerações Finais e Perspectivas Futuras

Nesta primeira etapa foi definido o algoritmo de machine learning utilizado e feitas as análises dos componentes para definição dos componentes mais importantes

## VII. Referências Agradecimentos

Agradecemos, primeiramente, às nossas famílias, pelo apoio incondicional, incentivo constante e compreensão ao longo de toda a nossa trajetória acadêmica. Sem esse suporte, a realização deste trabalho não seria possível.

Como inspiração para seguir em frente diante dos desafios, destacamos a frase de Walt Disney: “Todos