

# Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

<sup>1</sup> Lucas Kerr do Amaral, <sup>2</sup> Marcela Nalesso

<sup>1</sup> Ciência da Computação – FEI <sup>2</sup> Ciência da Computação – FEI

<sup>1</sup> lamaral2002@gmail.com, <sup>2</sup> marcelanalesso@gmail.com

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira laferreira@fei.edu.br

**Resumo:** Diante da insuficiência performática em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via *Principal Component Analysis* (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

**Palavras-chaves:** Sistemas de Detecção de Intrusões, Machine Learning, Segurança da Informação, Análise de Dados, Redução de Dimensionalidade e Cybersegurança.

## 1. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Com o aumento do volume de dados trafegados e da complexidade das infraestruturas, observa-se também um crescimento expressivo na quantidade e sofisticação dos ataques, como negações de serviço, varreduras de rede e acessos não autorizados. Esse cenário evidencia a necessidade de mecanismos eficazes de monitoramento e proteção, capazes de identificar comportamentos maliciosos em tempo hábil. Nesse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de *Machine Learning* tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender

exclusivamente de regras pré-definidas. No entanto, a eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD e UNSW-NB15 têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a *Principal Component Analysis* (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e

desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de *Machine Learning* aplicadas à detecção de intrusões, identificando atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de *Principal Component Analysis* (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em *Machine Learning*, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

## II. Fundamentação Teórica

teste

| ML Methods     | Coluna 1 | Coluna 2 | Coluna 3 |
|----------------|----------|----------|----------|
| <b>Linha 1</b> |          |          |          |
| a              | b        | c        | d        |
| <b>Linha 2</b> |          |          |          |
| a              | b        | c        | d        |
| <b>Linha 3</b> |          |          |          |
| a              | b        | c        | d        |

**Tabela I.** Summary of ML Methods—Advantages and Disadvantages

## III. Metodologia

## IV. Cronograma

| Etapas                                     | 2026 |     |     |     |     |
|--------------------------------------------|------|-----|-----|-----|-----|
|                                            | Fev  | Mar | Abr | Mai | Jun |
| Pesquisa para conhecimento do público-alvo | X    | X   |     |     |     |
| Pesquisa de opinião sobre o público-alvo   |      | X   | X   |     |     |
| Desenvolvimento do projeto                 |      |     | X   | X   |     |
| Testes e validação                         |      |     |     | X   | X   |
| Finalização do TCC                         |      |     |     |     | X   |

## V. Resultados Parciais

## VI. Considerações Finais e Perspectivas Futuras

Nesta primeira etapa foi definido o algoritmo de machine learning utilizado e feitas as análises dos componentes para definição dos componentes mais importantes

## VII. Referências

testando bilbiografia [1]

- [1] A. Khraisat, I. Gondal, P. Vamplew, J. Kamruzzaman e A. Alazab, “Hybrid Intrusion Detection System Based on the Stacking Ensemble of C5 Decision Tree Classifier and One Class Support Vector Machine,” p. 18, 2020. DOI: 10.339/90101173

## Agradecimentos

Agradecemos, primeiramente, às nossas famílias, pelo apoio incondicional, incentivo constante e compreensão ao longo de toda a nossa trajetória acadêmica. Sem esse suporte, a realização deste trabalho não seria possível.

Como inspiração para seguir em frente diante dos desafios, destacamos a frase de Walt Disney: “Todos os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los”.