

Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

¹ Lucas Kerr do Amaral, ² Marcela Nalesso

¹ Ciência da Computação – FEI ² Ciência da Computação – FEI

¹ lamaral2002@gmail.com, ² marcelanalesso@gmail.com

Orientador: Prof. Dr. Leonardo Anjoletto Ferreira laferreira@fei.edu.br

Resumo: Diante da insuficiência performática em métodos tradicionais, este artigo apresenta o desenvolvimento parcial de um sistema de detecção de intrusões em redes. As etapas incluem: i) coleta e preparação de dados com bases de ataques; ii) redução de dimensionalidade via *Principal Component Analysis* (PCA) e Matriz de Correlação; iii) análise exploratória para distinguir tráfego normal, ataques e falsos positivos; iv) implementação e avaliação preliminar de modelos de machine learning para classificação de intrusões. Resultados preliminares serão apresentados. Como contribuições futuras, prevê-se aprimoramento dos algoritmos, ajuste de hiperparâmetros à novos modelo, e evolução da sistema para tempo real e em cenários reais.

Palavras-chaves: Sistemas de Detecção de Intrusões, Machine Learning, Seguranças da sInformação, Análise de Dados, Redução de Dimensionalidade e Cybersegurança.

I. Introdução

O avanço das redes de computadores e a crescente digitalização de serviços têm ampliado significativamente a exposição de sistemas a ameaças cibernéticas. Com o aumento do volume de dados trafegados e da complexidade das infraestruturas, observa-se também um crescimento expressivo na quantidade e sofisticação dos ataques, como negações de serviço, varreduras de rede e acessos não autorizados. Esse cenário evidencia a necessidade de mecanismos eficazes de monitoramento e proteção, capazes de identificar comportamentos maliciosos em tempo hábil. Nesse contexto, a área de Segurança da Informação destaca-se como fundamental para garantir a integridade, confidencialidade e disponibilidade das informações.

Entre os mecanismos utilizados para proteção de redes, destacam-se os *Intrusion Detection System*, responsáveis por monitorar atividades e identificar possíveis intrusões. Tradicionalmente, esses sistemas baseiam-se em assinaturas ou regras previamente definidas, o que limita sua capacidade de detectar ataques desconhecidos ou variações de ameaças existentes. Como consequência, tais abordagens apresentam limitações relevantes, como elevada taxa de falsos positivos e baixa adaptabilidade a novos cenários. Dessa forma, torna-se necessário investigar abordagens mais flexíveis e inteligentes para aprimorar a detecção de intrusões.

Nesse sentido, o uso de técnicas de *Machine Learning* tem se consolidado como uma alternativa promissora. Esses métodos permitem a identificação de padrões complexos nos dados, possibilitando a detecção de comportamentos anômalos sem depender

exclusivamente de regras pré-definidas. No entanto, a eficácia desses modelos depende diretamente da qualidade dos dados utilizados, da seleção adequada de atributos e da capacidade de lidar com a alta dimensionalidade das bases. Assim, compreender a influência dessas variáveis torna-se essencial para o desenvolvimento de soluções mais eficientes.

Diante desse cenário, bases de dados como a NSL-KDD e UNSW-NB15 têm sido amplamente utilizadas para avaliação de técnicas de detecção de intrusão. Essas bases reúnem diferentes tipos de ataques e atributos de rede, permitindo a aplicação e comparação de modelos de classificação. Entretanto, a presença de grande quantidade de variáveis pode introduzir redundância e dificultar o aprendizado dos algoritmos, impactando negativamente seu desempenho. Nesse contexto, técnicas como a *Principal Component Analysis* (PCA) e Matriz de Correlação tornam-se relevantes para reduzir a dimensionalidade e destacar características mais significativas.

Considerando essas limitações, surge a necessidade de investigar de forma sistemática a relação entre atributos, técnicas de redução de dimensionalidade e desempenho de algoritmos de classificação. Estudos existentes frequentemente analisam esses elementos de forma isolada, não explorando de maneira integrada seu impacto na detecção de intrusões. Essa lacuna dificulta a identificação de abordagens mais eficientes e a construção de soluções práticas aplicáveis em ambientes reais. Assim, justifica-se a realização de uma análise abrangente que integre esses aspectos.

Dessa forma, este trabalho tem como objetivo geral analisar e avaliar técnicas de *Machine Learning* aplicadas à detecção de intrusões, identificando

atributos relevantes e comparando o desempenho de algoritmos de classificação. Especificamente, propõe-se:

- Realizar a análise exploratória das bases NSL-KDD e UNSW-NB15, para compreender sua estrutura, identificar características gerais dos dados e verificar a presença de inconsistências, valores ausentes ou desbalanceamento entre classes.
- Investigar a distribuição das classes e identificar padrões nos dados, buscando compreender o comportamento do tráfego de rede e possíveis distinções entre atividades normais e diferentes tipos de ataques.
- Aplicar a matriz de correlação para análise das variáveis, a fim de identificar relações entre atributos, detectar possíveis redundâncias e avaliar o impacto dessas correlações na modelagem dos dados.
- Utilizar a técnica de *Principal Component Analysis* (PCA) para reduzir a dimensionalidade do conjunto de dados, facilitando a visualização, interpretação e identificação de padrões relevantes.
- Treinar modelos de classificação baseados em *Machine Learning*, aplicando diferentes algoritmos com o objetivo de identificar padrões de intrusão e classificar o tráfego de rede.
- Avaliar o desempenho dos modelos por meio de métricas quantitativas, como acurácia, precisão, recall e F1-score, visando medir a eficácia dos algoritmos na detecção de intrusões.
- Comparar o desempenho dos diferentes algoritmos de classificação, analisando seus resultados e identificando aqueles mais adequados ao problema de detecção de intrusão em redes de computadores.

Os resultados obtidos servirão como base para o desenvolvimento de um protótipo de sistema de detecção de intrusão, contribuindo para o avanço de soluções mais eficazes na área.

II. Fundamentação Teórica

A. Segurança da Informação e Ameaças em Redes

A segurança da informação tornou-se um elemento central na sociedade contemporânea devido à crescente dependência de sistemas digitais. Com a consolidação da chamada “civilização cibernética”, iniciada a partir da revolução digital no final do século XX, houve um aumento significativo na produção e circulação de dados, ampliando a superfície de ataque para agentes maliciosos [14]. Dados recentes indicam que o tráfego global per capita evoluiu de 16 GB mensais em 2017 para projeções superiores a 50 GB em

2022, enquanto mais de 14 bilhões de registros foram comprometidos desde 2013, evidenciando a magnitude das ameaças digitais [4] [15]. Nesse contexto, a Segurança da Informação fundamenta-se na preservação da tríade confidencialidade, integridade e disponibilidade, tornando-se essencial para a proteção de ativos digitais em ambientes cada vez mais interconectados [3] [4] [9].

A evolução das ameaças cibernéticas acompanha diretamente o avanço tecnológico, tornando os ataques mais sofisticados e diversificados. Entre os principais tipos de ataques identificados na literatura estão os ataques de negação de serviço (DoS), varreduras de rede (Probe), acessos remotos não autorizados (R2L) e escalonamento de privilégios (U2R), cada um explorando vulnerabilidades específicas dos sistemas [3]. Além disso, observa-se o crescimento expressivo dos ataques de dia zero, que exploram falhas ainda desconhecidas, dificultando a detecção por mecanismos tradicionais. Dessa forma, a complexidade e o volume das ameaças exigem soluções capazes de operar em ambientes de grande escala e alta velocidade.

No presente, mais de 61% das interações industriais e sociais ocorrem em ambiente online, o que torna a rede um alvo estratégico para cibercrimes que agora visam não apenas usuários finais, mas diretamente infraestruturas críticas e instituições bancárias. Essa dependência tecnológica exige que os Sistemas de Detecção de Intrusão (IDS) evoluam proporcionalmente à sofisticação das ameaças [3].

B. Sistemas de Detecção de Intrusão

Os Intrusion Detection System constituem uma das principais ferramentas para monitoramento e identificação de atividades maliciosas em redes. Desde o primeiro modelo formal proposto em 1987, os IDS evoluíram de abordagens estatísticas simples para sistemas inteligentes capazes de analisar grandes volumes de dados em tempo real [14]. Esses sistemas atuam como uma camada adicional de segurança, monitorando eventos e gerando alertas quando comportamentos suspeitos são identificados. Assim, os IDS desempenham papel fundamental na mitigação de ataques e na proteção de infraestruturas críticas.

Os IDS podem ser classificados tanto pela fonte de dados quanto pela abordagem de detecção. Em relação à origem das informações, destacam-se os sistemas baseados em rede (NIDS) e os baseados em host (HIDS) [3] [12], enquanto, quanto à técnica utilizada, dividem-se em sistemas baseados em assinatura (SIDS) e baseados em anomalia (AIDS) [8] [15] [1]. Os sistemas baseados em assinatura são eficazes na identificação de ataques conhecidos, porém incapazes de detectar ameaças inéditas, como ataques de dia zero [4] [14]. Por outro lado, os sistemas baseados em anomalia apresentam maior flexibilidade, mas

sofrem com altas taxas de falsos positivos, o que impacta diretamente sua aplicabilidade prática [15] [13].

A literatura destaca que os IDS enfrentam desafios significativos relacionados ao volume e à complexidade dos dados de rede. Com o crescimento exponencial do tráfego e a geração massiva de dados, os sistemas tradicionais tornam-se incapazes de processar informações em tempo real sem perda de desempenho. Além disso, a presença de atributos redundantes e irrelevantes nos datasets compromete a eficiência dos modelos de detecção. Esse cenário evidencia a necessidade de soluções mais inteligentes e adaptativas, capazes de lidar com ambientes de Big Data.

C. Machine Learning aplicado à detecção de intrusão

O Machine Learning surge como uma abordagem promissora para superar as limitações dos IDS tradicionais. Ao permitir que sistemas aprendam padrões diretamente dos dados, o aprendizado de máquina possibilita a identificação de comportamentos anômalos e a adaptação a novos tipos de ataques [7] [12] [8]. Estudos recentes apontam um crescimento significativo no uso de técnicas de ML e Deep Learning na detecção de intrusões, especialmente a partir de 2018. Dessa forma, o ML se consolida como um componente essencial para o desenvolvimento de IDS mais eficientes.

Entre os paradigmas de aprendizado, o modelo supervisionado destaca-se como o mais utilizado na literatura [14] [8]. Essa abordagem utiliza dados previamente rotulados para treinar modelos capazes de classificar o tráfego de rede como normal ou malicioso. A disponibilidade de bases de dados como NSL-KDD e CICIDS-2017 favorece a aplicação desse tipo de técnica, permitindo comparações padronizadas entre diferentes modelos. Assim, o aprendizado supervisionado torna-se a base para a construção de sistemas de detecção mais precisos.

Entretanto, a aplicação de ML em IDS enfrenta desafios relacionados à alta dimensionalidade dos dados. A presença de atributos redundantes aumenta o custo computacional e pode reduzir a acurácia dos modelos. Nesse contexto, técnicas de seleção de atributos tornam-se essenciais para identificar características relevantes e reduzir a complexidade do sistema. A literatura demonstra que é possível reduzir significativamente o número de atributos sem perda de desempenho, melhorando a eficiência dos modelos [6].

D. Algoritmos de classificação

Diversos algoritmos de classificação têm sido aplicados na detecção de intrusões, cada um apresentando vantagens e limitações específicas. Entre os mais utilizados destacam-se o Random Forest, o Support Vector Machine, o K-Nearest Neighbors, as árvores de

decisão e o Naive Bayes. Esses algoritmos diferem em termos de desempenho, complexidade computacional e capacidade de generalização. Dessa forma, a escolha do modelo adequado depende diretamente das características do conjunto de dados e do problema abordado.

O Random Forest destaca-se pela alta acurácia e robustez, alcançando taxas superiores a 99% em bases como KDD Cup 99 e NSL-KDD [2] [5]. Esse algoritmo utiliza múltiplas árvores de decisão para reduzir o risco de sobreajuste. Por outro lado, o SVM apresenta bom desempenho em espaços de alta dimensionalidade, embora sua eficiência dependa fortemente da escolha dos parâmetros [2] [4] [13]. Assim, ambos os algoritmos são amplamente utilizados em cenários de detecção de intrusão.

Outros algoritmos também desempenham papel relevante na literatura. O KNN destaca-se pela simplicidade, mas possui alto custo computacional na fase de classificação, enquanto as árvores de decisão oferecem interpretabilidade, sendo úteis para análise de regras [2] [8] [4]. Já o Naive Bayes apresenta boa eficiência computacional, embora sua suposição de independência entre atributos possa limitar seu desempenho [2] [8] [11]. Dessa forma, a combinação de diferentes algoritmos, por meio de técnicas ensemble, tem sido explorada para melhorar os resultados.

Estudos indicam que a integração entre algoritmos de classificação e técnicas de seleção de atributos é fundamental para alcançar alto desempenho em IDS [2] [10]. A redução de dimensionalidade permite diminuir o custo computacional e aumentar a velocidade de processamento, especialmente em redes de alta velocidade. Além disso, a escolha adequada de atributos contribui diretamente para a melhoria da acurácia e redução de falsos positivos [6]. Assim, a combinação dessas técnicas representa uma abordagem eficaz para a construção de sistemas de detecção mais robustos.

E. Métricas de Avaliação

III. Cronograma

Etapas	2026				
	Fev	Mar	Abr	Mai	Jun
Pesquisa para conhecimento do público-alvo	X	X			
Pesquisa de opinião sobre o público-alvo		X	X		
Desenvolvimento do projeto			X	X	
Testes e validação				X	X
Finalização do TCC					X

IV. Resultados Preliminares

A. Análise de Dados e Pré-processamento

Para a análise de dados foi considerado a base de dados NSL-KDD com os seguintes

ataques: *neptune*, *satan*, *ipsweep*, *poetsweep*, *smurf*, *nmap*, *back*, *teardrop*, *warezclient*, *pod*, *guess_passwd*, *buffer_overflow*, *warezmaster*, *land*, *imap*, *rootkit*, *loadmodule*, *ftp_write*, *multihop*, *phf*, *perl*, *spy*. alguns dos valores citados não são ataques reais, porém no contexto desta análise componentes como: *loadmodule*, *perl* e *nmap* foram categorizados como ataques.

normal	67343
neptune	41214
satan	3633
ipsweep	3599
portsweep	2931
smurf	2646
nmap	1493
back	956
teardrop	892
warezclient	890
pod	201
guess_passwd	53
buffer_overflow	30
warezmaster	20
land	18
imap	11
rootkit	10
loadmodule	9
ftp_write	8
multihop	7
phf	4
perl	3
spy	2

Tabela I. Dados presentes na base NSL-KDD

Para melhor visualização dos dados os ataques foram separados nas seguintes categorias: *normal*, *dos*, *probe*, *r2l*, *u2r*.

Categoria	Tipos de Ataque
normal	Normal
dos	Neptune smurf teardrop pod land
probe	nmap ipsweep satan
r2l	warezclient warezmaster guess_passwd imap ftp_write multihop phf spy
u2r	buffer_overflow rootkit loadmodule perl

Tabela II. Definição de tipos de ataque por grupos

A matriz de correlação mostra que, a contagem de pacotes e ocorrência de erros são os componentes com maior correlação.




Figura 1. Matriz de correlação da base NSL_KDD

Para validar as informações da matriz de correlação foi feita uma análise baseada em *PCA*, plotando um gráfico com os dois primeiros componentes e separando os valores pelos grupos anteriormente mencionados na tabela ??.




Figura 2. visualização de dois componentes do PCA separado por classes

B. Redução de Dimensionalidade e Seleção de Atributos

Buscando uma margem de variância a cima de 95% foi calculado o *PCA* para variados números de componentes, para descobrir a melhor variância, com o menor número de componentes. Definido 23 componentes como a melhor média amostral




Figura 3. Variância explicada para PCA

V. Metodologia

O algoritmo utilizado para as análises foi o *DecisionTree*, este conta com o menor tempo de teste e melhor acurácia, estes valores são a maior métrica utilizada pois o objetivo do sistema é ser executado em tempo real para garantir uma resposta rápida a incidentes.

Utilizando os testes do capítulo anterior, foi desenvolvida uma análise com os variados algoritmos mais utilizados (*RandomForest*, *DecisionTree*, *KNN*,

SVM, *LogisticRegression*). Utilizando um random state de 42 para os algoritmos citados, obtiveram-se os seguintes valores:

Modelo	Acurácia	Precisão	Recall	F1-Score
Random Forest	0.9987	0.9992	0.9979	0.9985
Decision Tree	0.9977	0.9975	0.9975	0.9975
KNN	0.9935	0.9921	0.9940	0.9931
Logistic Regression	0.9454	0.9504	0.9313	0.9408
SVM (linear)	0.9544	0.9594	0.9418	0.9506

Tabela III. Estatísticas de treino dos modelos

Dados os valores da tabela ?? o algoritmo selecionado foi o *Decision Tree*, dado seu baixo tempo de teste e alta acurácia.

Utilizando os valores anteriormente definidos na figura ?? para uma melhor visualização dos dados que realmente importam, o gráfico foi dividido entre ataques e tráfego normal:




Figura 4. PCA classificando tráfego como ataque e normal

Estudando as features com o auxilio dos resultados do *PCA* chegou-se a Conclusão que com 7 features é possível alcançar uma acurácia com valores a cima de 95%:




Figura 5. Representação da importância de cada feature para a acurácia

Afim de refinar os dados representado no PCA pela imagem ?? uma análise similar foi feita utilizando o algoritmo *DecisionTree*:




Figura 6. Features variadas para o decision tree

Indicando que o número ótimo de features é 18, onde a acurácia é maior. Sendo elas:

1. src_bytes
2. dst_host_srv_count
3. count
4. dst_bytes
5. dst_host_srv_error_rate
6. hot
7. dst_host_same_src_port_rate
8. logged_in
9. srv_count
10. dst_host_same_srv_rate
11. duration
12. wrong_fragment
13. dst_host_rerror_rate
14. dst_host_diff_srv_rate
15. dst_host_count
16. dst_host_srv_diff_host_rate
17. dst_host_serror_rate
18. diff_srv_rate

VI. Considerações Finais e Perspectivas Futuras

Nesta primeira etapa foi definido o algoritmo de machine learning utilizado e feitas as análises dos componentes para definição dos componentes mais importantes

VII. Referências

- [1] E. E. Abdallah, W. Eleisah e A. F. Otoom, "Intrusion Detection Systems using Supervised Machine Learning Techniques: A survey," 2022. DOI: 10.1016/2022.03.029
- [2] O. H. Abdulganiyu, T. A. Tchakoucht e Y. K. Saheed, "A systematic literature review for network intrusion detection system (IDS)," *International Journal of Information Security*, vol. 22, pp. 1233–1262, 2023. DOI: 10.1007/s10207-023-00682-2
- [3] W. S. Admass, Y. Y. Munaye e A. A. Diro, "Cyber security: State of the art, challenges and future directions," 2023. DOI: 10.1016/2023.10031
- [4] Z. Azam, M. M. Islam e M. N. Huda, "Comparative Analysis of Intrusion Detection Systems and Machine Learning-Based Model Analysis Through Decision Tree," 2023. DOI: 10.1109/2023.3296444
- [5] M. C. Belavagi e B. Muniyal, "Performance Evaluation of Supervised Machine Learning Algorithms for Intrusion Detection," *Procedia Computer Science*, vol. 89, pp. 117–123, 2016. DOI: 10.1016/j.procs.2016.06.016
- [6] F. Iglesias e T. Zseby, "Analysis of network traffic features for anomaly detection," 2014. DOI: 10.1007/10994-014-5473-9

- [7] J. Jabez e B. Muthukumar, “Intrusion Detection System (IDS): Anomaly Detection Using Outlier Detection Approach,” *Procedia Computer Science*, vol. 48, pp. 338–343, 2015. DOI: 10.1016/j.procs.2015.04.191
- [8] A. Khraisat, I. Gondal, P. Vamplew e J. Kamruzzaman, “Survey of intrusion detection systems: techniques, datasets and challenges,” *Cybersecurity*, vol. 2, n.º 1, pp. 1–22, 2019. DOI: 10.1186/s42400-019-0038-7
- [9] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin e K.-Y. Tung, “Intrusion detection system: A comprehensive review,” *Journal of Network and Computer Applications*, vol. 36, n.º 1, pp. 16–24, 2013. DOI: 10.1016/j.jnca.2012.09.004
- [10] S. M. Othman, F. M. Ba-Alwi, T. Nabeel e A. Y. Al-Hashida, “Intrusion detection model using machine learning algorithm on Big Data environment,” *Journal of Big Data*, vol. 5, n.º 1, p. 34, 2018. DOI: 10.1186/s40537-018-0145-4
- [11] M. M. Rathore, A. Ahmad e A. Paul, “Real time intrusion detection system for ultra-high-speed big data environments,” *The Journal of Supercomputing*, vol. 72, n.º 9, pp. 3489–3510, 2016. DOI: 10.1007/s11227-015-1615-5
- [12] T. Saranya, S. Sridevi, C. Deisy, T. D. Chung e M. K. A. A. Khan, “Performance Analysis of Machine Learning Algorithms in Intrusion Detection System: A Review,” *Procedia Computer Science*, vol. 171, pp. 1251–1260, 2020. DOI: 10.1016/j.procs.2020.04.133
- [13] S. A. R. Shah e B. Issac, “Performance comparison of intrusion detection systems and application of machine learning to Snort system,” *Future Generation Computer Systems*, vol. 80, pp. 157–170, 2018. DOI: 10.1016/j.future.2017.10.016
- [14] K. A. Taher, B. M. Y. Jisan, Md. e M. Rahman, “Network Intrusion Detection using Supervised Machine Learning Technique with Feature Selection,” 2019. DOI: 10.1109/2019.0644161
- [15] A. Thakkar e R. Lohiya, “A survey on intrusion detection system: feature selection, model, performance measures, application perspective, challenges, and future research directions,” *Artificial Intelligence Review*, vol. 54, pp. 4529–4593, 2021. DOI: 10.1007/s10462-021-10037-9

Como inspiração para seguir em frente diante dos desafios, destacamos a frase de Walt Disney: “Todos os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los”.

Agradecimentos

Agradecemos, primeiramente, às nossas famílias, pelo apoio incondicional, incentivo constante e compreensão ao longo de toda a nossa trajetória acadêmica. Sem esse suporte, a realização deste trabalho não seria possível.