

TCC 1º SEMESTRE / 2026

Tecnologias de Machine Learning para Detecção de Intrusões em Redes de Computadores

Uma Pesquisa Exploratória e Experimental

Integrantes:

Lucas Kerr do Amaral
Marcela Nalesso

Orientador

Prof. Dr. Leonardo Anjoletto Ferreira

Ciência da Computação
FEI - São Bernardo do Campo

INTRODUÇÃO E CONTEXTO

Crescimento de Tráfego

16 GB → 50 GB

Tráfego mensal por usuário (2017 - 2022)

A digitalização acelerada expandiu a superfície de ataque cibernético de forma crítica e irreversível.

Fonte: SHAH, S. A. R. et al, 2018

Exposição de Dados

+14 Bilhões

Registros vazados desde 2013

O volume massivo de dados circulando reforça a necessidade urgente de sistemas de segurança multicamadas e robustos.

Fonte: AZAM, Z. et al, 2023

TIPOS DE IDS

HIDS (Baseado em Host)

- Análise de arquivos do sistema, chamadas do sistema e logs do SO.
- **Vantagens:** Visibilidade profunda sobre os pontos vulneráveis
- **Desvantagens:** Consome recursos dos equipamentos

NIDS (Baseado em Redes)

- Análise do tráfego da infraestrutura, comunicação entre dispositivos
- **Vantagens:** Monitoramento abrangente da rede interna, e centralização de consumo de recursos.
- **Desvantagens:** Dificuldade de processamento de dados em redes de alta velocidade.

ABORDAGENS DA IDS

SIDS (Baseado em Assinatura)



Mecanismo

Correspondência exata de padrões conhecidos (Regras If-Then).

Ponto Forte

Exatidão extrema e instantânea para ameaças catalogadas (Baixíssima taxa de falsos positivos).

Ponto Cego

Completamente inútil contra ataques zero-day ou variantes polimórficas (reativo).

AIDS (Baseado em Anomalia)



Mecanismo

Modelagem estatística do comportamento 'normal' do usuário ou da rede.

Ponto Forte

Detecta ataques inéditos (zero-day) identificando desvios e anomalias proativamente.

Ponto Cego

Alta Taxa de Falsos Positivos (atividades legítimas, porém raras, são tratadas como intrusões).

LIMITAÇÕES DOS MÉTODOS TRADICIONAIS



Base em Assinaturas

Sistemas tradicionais dependem de regras pré-definidas, falhando em identificar ameaças desconhecidas.



Falsos Positivos

Elevada taxa de alarmes falsos em tráfegos legítimos, sobrecarregando as equipes de TI.




Ataques Zero Day

Incapacidade de resposta a vulnerabilidades exploradas antes mesmo de serem catalogadas.

OBJETIVOS DA PESQUISA

Analisar a base NSL-KDD, identificando sua estrutura, inconsistências e desbalanceamentos.



1

2



Investigar a distribuição das classes e os padrões do tráfego de rede, diferenciando atividades normais e ataques.

Avaliar os modelos com métricas como acurácia, precisão, recall e F1-score na detecção de intrusões.



3

FUNDAMENTAÇÃO: A TRÍADE CIA

O foco central é a proteção contra ameaças internas e externas através de três pilares:



Confidencialidade

Garantir que os dados sejam acessados apenas por entidades autorizadas.



Integridade


Assegurar que as informações não sejam alteradas de forma indevida.



Disponibilidade

Garantir acesso contínuo aos serviços e dados para usuários legítimos.

METODOLOGIA



Fonte: Autor

SOBRE A NSL-KDD

Componentes

- A base de dados NSL-KDD é uma versão aprimorada da KDD Cup 1999, amplamente utilizada em pesquisas relacionadas à detecção de intrusões em redes.
- Seu principal objetivo é **fornecer um conjunto de dados mais equilibrado e confiável para avaliação de modelos de aprendizado de máquina**, reduzindo problemas presentes na base original, como registros redundantes e vieses nos resultados. A NSL-KDD contém diferentes **tipos de tráfego de rede, classificados entre atividades normais e ataques**, permitindo o treinamento e a validação de sistemas de detecção de intrusão (IDS).

normal	67343
neptune	41214
satan	3633
ipsweep	3599
portsweep	2931
smurf	2646
nmap	1493
back	956
teardrop	892
warezclient	890
pod	201
guess_passwd	53
buffer_overflow	30
warezmaster	20
land	18
imap	11
rootkit	10
loadmodule	9
ftp_write	8
multihop	7
phf	4
perl	3
spy	2

Fonte: Autor

ESTATÍSTICA DE TREINO DOS MODELOS

MODELO	ACC	PREC	F1-SCORE	TEMPO TREINO (S)	TEMPO TESTE (S)
Random Forest (RF)	0.9987	0.9992	0.9985	6.3216	0.1268
Decision Tree (DT)	0.9977	0.9975	0.9975	0.8541	0.0035
KNN (k=5)	0.9935	0.9921	0.9931	0.0052	16.5641
Logistic Regression	0.9454	0.9504	0.9408	3.0691	0.0037
SVM	0.9544	0.9594	0.9506	217.7609	9.0564

Dados extraídos dos experimentos preliminares com a base NSL-KDD

SELEÇÃO: DECISION TREE (DT)

0.0035_s

Tempo de Teste

O menor entre todos os modelos testados.

Por que a Árvore de Decisão?

Para um sistema de detecção em tempo real, a **baixa latência de resposta** é prioritária.


- Alta Acurácia (99,77%)
- Baixíssimo custo computacional
- Fácil interpretabilidade dos ramos

ANÁLISE DE PCA E VISUALIZAÇÃO


Principal Component Analysis (PCA)

Utilizado para reduzir a dimensionalidade dos dados (originalmente com 41 atributos no KDD) para componentes mais significativos.


Variância Explicada: 23 componentes foram definidos para manter uma margem acima de 95% de fidelidade aos dados originais.



Fonte: Autor




Fonte: Autor



Fonte: Autor

MATRIZ DE CORRELAÇÃO




Fonte: Autor

OTIMIZAÇÃO DAS 18 FEATURES




Identificamos que **18 atributos** são o número ótimo para maximizar a acurácia sem redundância de dados.

Com apenas **7 features**, já é possível atingir uma acurácia superior a **95%**, permitindo implementações ultra-rápidas.




Fonte: Autor



Fonte: Autor

CRONOGRAMA DO PROJETO



CONCLUSÕES E PASSOS FUTUROS

Contribuições

- Validação da Decision Tree como modelo performático para IDS.
- Análise integrada de redução de dimensionalidade e métricas.
- Identificação de 18 atributos críticos para detecção.

Perspectivas

- Evolução do sistema para monitoramento em tempo real.
- Ajuste de hiperparâmetros para novos modelos.
- Aplicação em cenários reais além das bases experimentais.

Dúvidas?

"Todos os seus sonhos podem se tornar realidade se você tiver a coragem para persegui-los."

- Walt Disney

Lucas Kerr do Amaral

RA: 22.123.032-9

Marcela Nalesso

RA: 22.222.011-3

Referências Bibliográficas

- 1) E. E. Abdallah, W. Eleisah e A. F. Otoom, "Intrusion Detection Systems using Supervised Machine Learning Techniques: A survey," 2022. doi: 10.1016/2022.03.029
- 2) O. H. Abdulganiyu, T. A. Tchakoucht e Y. K. Saheed, "A systematic literature review for network intrusion detection system (IDS)," International Journal of Information Security, vol. 22, pp. 1233–1262, 2023. doi: 10.1007/s10207-023-00682-2
- 3) W. S. Admass, Y. Y. Munaye e A. A. Diro, "Cyber security: State of the art, challenges and future directions," 2023. doi: 10.1016/2023. 10031
- 4) Z. Azam, M. M. Islam e M. N. Huda, "Comparative Analysis of Intrusion Detection Systems and Machine Learning-Based Model Analysis Through Decision Tree," 2023. doi: 10.1109/ 2023.3296444
- 5) M. C. Belavagi e B. Muniyal, "Performance Evaluation of Supervised Machine Learning Algorithms for Intrusion Detection," Procedia Computer Science, vol. 89, pp. 117–123, 2016. doi: 10.1016/j.procs.2016.06.016
- 6) I. Belcic e C. Stryker, O que é aprendizado supervisionado? 2026. URL: <https://www.ibm.com/br-pt/think/topics/supervised-learning>
- 7) O. Depren, M. Topallar, E. Anarim e M. K. Ciliz, "An intelligent intrusion detection system (IDS) for anomaly and misuse detection in computer networks," Expert Systems with Applications, vol. 29, n.º 4, pp. 713–722, 2005. doi: 10.1016/j.eswa.2005.05.002
- 8) S. Duquea e D. N. bin Omar, "Using Data Mining Algorithms for Developing a Model for Intrusion Detection System (IDS)," 2015. doi: 10.1016/j.procs.2015.09.145
- 9) J. G., W. D., H. T., T. R. e T. J., An Introduction to Statistical Learning with Applications in Python. 2023. doi: 10.1007/978-3-031 38747-0_2
- 10) X. Gao, C. Shan, C. Hu, Z. Niu e Z. Liu, "An Adaptive Ensemble Machine Learning Model for Intrusion Detection," 2019. doi: 10.1109/ACCESS.2019.2923640
- 11) D. Ghelani, "Cyber Security, Cyber Threats, Implications and Future Perspectives: A Re view," 2022. doi: 10. 11648 / j . XXXX . 2022XXXX.XX
- 12) F. Iglesias e T. Zseby, "Analysis of network traf fic features for anomaly detection," 2014. doi: 10.1007/10994-014-5473-9
- 13) J. Jabez e B. Muthukumar, "Intrusion Detec tion System (IDS): Anomaly Detection Using Outlier Detection Approach," Procedia Computer Science, vol. 48, pp. 338–343, 2015. doi: 10.1016/j.procs.2015.04.191
- 14) A. Khraisat, I. Gondal, P. Vamplew e J. Kam ruzzaman, "Survey of intrusion detection sys tems: techniques, datasets and challenges," Cy bersecurity, vol. 2, n.º 1, pp. 1–22, 2019. doi: 10.1186/s42400-019-0038-7
- 15) A. Khraisat, I. Gondal, P. Vamplew, J. Kam ruzzaman e A. Alazab, "Hybrid Intrusion De tection System Based on the Stacking Ensem ble of C5 Decision Tree Classifier and One Class Support Vector Machine," Electronics, vol. 8, n.º 9, p. 1011, 2019. doi: 10.3390/ electronics8091011
- 16) H.-J. Liao, C.-H. R. Lin, Y.-C. Lin e K.-Y. Tung, "Intrusion detection system: A compre hensive review," Journal of Network and Com puter Applications, vol. 36, n.º 1, pp. 16–24, 2013. doi: 10.1016/j.jnca.2012.09.004
- 17) S.M.Othman,F.M.Ba-Alwi,T.NabeeleA.Y. Al-Hashida, "Intrusion detection model using machine learning algorithm on Big Data envi ronment," Journal of Big Data, vol. 5, n.º 1, p. 34, 2018. doi: 10.1186/s40537-018-0145-4

Referências Bibliográficas

- 18) M.M.Rathore, A.AhmadeA.Paul, "Realtime intrusion detection system for ultra-high-speed big data environments," The Journal of Super computing, vol. 72, n.º 9, pp. 3489–3510, 2016. doi: 10.1007/s11227-015-1615-5
- 19) T. Saranya, S. Sridevi, C. Deisy, T. D. Chung e M. K. A. A. Khan, "Performance Analysis of Machine Learning Algorithms in Intrusion Detection System: A Review," Procedia Computer Science, vol. 171, pp. 1251–1260, 2020. doi: 10.1016/j.procs.2020.04.133
- 20) Scikit-Learn, scikit-learn: Machine Learning in Python, 2026. URL: <https://scikit-learn.org/stable/index.html>
- 21) S. A. R. Shah e B. Issac, "Performance comparison of intrusion detection systems and application of machine learning to Snort system," Future Generation Computer Systems, vol. 80, pp. 157–170, 2018. doi: 10.1016/j.future.2017.10.016
- 22) K. A. Taher, B. M. Y. Jisan, Md. e M. Rahman, "Network Intrusion Detection using Supervised Machine Learning Technique with Feature Selection," 2019. doi: 10.1109/2019.0644161
- 23) A. Thakkar e R. Lohiya, "A survey on intrusion detection system: feature selection, model, performance measures, application perspective, challenges, and future research directions," Artificial Intelligence Review, vol. 54, pp. 4529–4593, 2021. doi: 10.1007/s10462-021-10037-9
- 24) P. Vanin et al., "A Study of Network Intrusion Detection Systems Using Artificial Intelligence/Machine Learning," 2022. doi: 10.3390/app122211752